

DEEP-DREAM: 面向智能体长期记忆的时序概念图谱

(中文逐句对应版; 图表与数值宏与英文版共用)

Anonymous authors

Paper under double-blind review

ABSTRACT

大模型智能体的长期记忆会不断增长, 而其中同一个实体的状态也可能发生根本变化。人类回忆并不会因为后来获得了新知识, 就改写当时形成的一段记忆; 回忆时, 人们会把它放回当时的历史语境中理解。智能体面临同样的问题, 而且上下文窗口是有限的。把全部历史搬入窗口代价太高, 而在问题出现之前就把历史压缩成摘要, 又可能丢掉决定答案正确与否的限定条件。Deep-Dream 围绕这两个要求设计。系统不改写文档和原文片段, 只维护由概念、关系、观测和版本组成的关联访问层。提问时, 智能体沿着这些链接跨文档查找, 按需打开原文片段; 如果当前证据不足, 还可以继续展开多跳路径。在写入早期, 对于信息不足的实体提及, 系统先保留多个候选实体族, 而不是强行确定一个身份。随着后续观测和关系邻域逐渐丰富, 候选实体可以被对齐或重定向, 同时原始证据始终保留。我们在 MemoryAgentBench、LongMemEval、LoCoMo 和 MEME 四个公开基准上评测该设计。MemoryAgentBench 的原文支撑读取达到 71.0%, 接近同一回答模型直接读取完整上下文的 78.7%; LoCoMo 达到 95.19%。延迟实体对齐使入库调用减少 46-65%, 同时保持相近的抽样质量。结果说明, 可修订的访问层和由智能体控制的原文读取能够支持长期记忆; MEME 也表明, 删除历史需要额外的明确抑制机制。

1 引言

一个记忆回答至少涉及三层证据: 文档写了什么, 系统如何把句子链接到实体, 以及智能体实际读了哪些段落。把三者混在一起, 会让看似合理的答案难以审计。假设文档写着“Alex 批准了合同”, 而集合中有一位实验室的 Alex 和一位供应商的 Alex。这句话支持“发生过批准”这一说法, 却不足以确定身份。后续的组织信息或关系证据可能改变链接; 过早合并则可能让错误的历史看起来像权威记录。

更新事实也有同样的校准问题。一位朋友一月说“我暂时不吃辣”, 六月又说“我现在可以吃辣了”。两句话都是证据; 回答当前偏好时应使用后一句, 而解释变化过程时则需要查看两句。因此, 保留记录和解释记录需要分属不同状态。

Deep-Dream 以文档优先的时间概念图实现这种分离。文档、Episode 及精确来源偏移保留原始记录; 观测把抽取内容链接到原文片段, 概念、关系、版本和候选族提供可修订的访问路径。新证据可以重定向链接而不改写来源。处理时间负责排列更新顺序, 文档中的日期仍是观测内容。这是一种可审计的表示, 并不保证实体解析正确, 也不保证实现能够恢复任意历史图状态。

查询时, 智能体沿地址打开来源段落, 并判断证据是否充分 (Figure 1)。它可以再次检索、检查关系邻域, 或比较前后措辞。**来源门只验证来源, 不验证身份或蕴含关系。**因此, 来源引用不能被误当作答案正确性的证明。

我们用配对构建实验、MemoryAgentBench 读取路径、LongMemEval 与 LoCoMo 历史测试, 以及 MEME 删除检查评估两个轴。比较结果严格按协议解释: 完整路径不是组件消融, 同名计数只是代理指标, 来源证明也不等于蕴含证明。本文贡献包括:




图 1: 存储与读取暴露的是不同的证据主张。可修订地址引导检索；原文段落让智能体审计措辞、身份语境和更新状态。

- **校准式证据存储**。带来源链接的观测保持可检查，推断出的身份链接可以修订。
- **可审计的渐进读取**。智能体能够收集更多段落，并展示某个地址背后的证据。
- **双轴评估**。在明确协议边界的前提下报告质量、覆盖、成本、对齐不确定性、图检索零结果和删除失败。

2 相关工作

长期记忆基准。 LoCoMo 和 LongMemEval 评估长对话、时序更新和多会话检索 (Maharana et al., 2024; Wu et al., 2025)。MEME 增加删除、级联影响和缺失事实问题 (Jung et al., 2026)。MemoryAgentBench (MAB) 在一个评分框架中同时测试准确检索、时序与测试时学习、长程理解和选择性遗忘 (Hu et al., 2025)。这些基准分别覆盖存储和读取的不同部分，因此本文将它们作为互补测试，而不把长期记忆压缩成一个分数。

智能体记忆系统。 MemGPT 将上下文管理描述为工作窗口与外部存储之间的分页 (Packer et al., 2023)。Model-Native Computing Architecture 进一步把上下文容量、缓存复用和智能体调度放在系统级资源管理框架下讨论 (Lin et al., 2026)。Mem0、Zep/Graphiti、HippoRAG-2、A-MEM、MIRIX 和 Cognee 使用摘要、笔记、图或它们的组合来保存跨会话信息 (Chhikara et al., 2025; Rasmussen et al., 2025; Gutiérrez et al., 2025; Xu et al., 2025; Wang & Chen, 2025; Markovic et al., 2025)。这些系统在“什么被保存为记忆”上各有不同：Deep-Dream 保留源文档，并把概念和关系作为指向源文档的链接，因此图中的派生节点是检索入口，而不是替代事实。

时序与版本化知识。 时序知识图谱表示不断变化的实体和关系；概率记录链接则区分错误合并与漏匹配 (Fellegi & Sunter, 1969)。Deep-Dream 将这些思想用于智能体记忆：处理时间排列观测和版本，延迟对齐使候选身份在证据充分之前保持可修订，源文本则始终保持不变。事件日期仍然属于观测内容，可以参与检索，但不会另建一套状态时钟。

压缩、检索与证据。 信息瓶颈和率失真理论研究紧凑表示与目标信息之间的取舍 (Tishby et al., 2000; Shannon, 1959)。联想记忆研究如何从部分线索中检索内容 (Ram-sauer et al., 2021)，检索增强生成则从外部来源选择生成证据 (Lewis et al., 2020)。长上下文模型在相关片段埋藏于大窗口中时可能丢失信息 (Liu et al., 2024)；归因研究检查回答是否引用了来源 (Gao et al., 2023)。Deep-Dream 将这些思想放入持久化记忆：概念和关系缩小搜索范围，源文本保留原始措辞，智能体决定读取多少内容；第 3.5 节给出这一分工的形式化分析。

智能体检索。 A-RAG 将关键词、语义和片段读取工具交给推理模型，用于多跳检索 (Du et al., 2026)。Deep-Dream 同样允许模型选择下一步读取动作，但面向的是不断变化的个人历史。它进一步需要处理身份修订、版本链接、跨文档 Episode 和基于原文的验证。

3 DEEP-DREAM

3.1 记忆表示

设 $\mathcal{D}_t$ 是截至处理时刻 t 已处理的文档集合。对 $D \in \mathcal{D}_t$ ，设 $\mathcal{E}(D)$ 是从该文档不可修改的原文片段中切分出的 Episode。对 $e_i \in \mathcal{E}(D_i)$ ，定义一条存储观测为

$$o_i = (D_i, e_i, \tau_i, x_i, \ell_i),$$

其中 τ_i 是处理时间， x_i 是抽取出的内容和属性， ℓ_i 是它在 D_i 中的精确原文位置。写入 t 条观测后的观测库为 $O_t = \{o_1, \dots, o_t\}$ 。持久化状态为

$$M_t = (F_t, O_t, G_t),$$

其中 F_t 保存概念实体族和候选身份， G_t 保存关系、邻域与版本指针。每条观测都携带文档和 Episode 标识 (D_i, e_i) ，用它们可以重新定位原文。

一次写入状态转移表示为

$$\begin{aligned} F_{t+1} &= \text{Align}(F_t, x_{t+1}), \\ O_{t+1} &= O_t \cup \{o_{t+1}\}, \\ G_{t+1} &= \text{Link}(G_t, F_{t+1}, o_{t+1}), \\ M_{t+1} &= (F_{t+1}, O_{t+1}, G_{t+1}). \end{aligned} \tag{1}$$

这里 **Align** 要么把 x_{t+1} 分配到已有实体族，要么先保留一个新的候选实体族；**Link** 在实体族、观测和版本之间增加或重定向指针。两种操作都不会修改 ℓ_{t+1} 所指向的原文。由于版本指针保留了早期状态，沿版本链定义的投影 π_t 可以从 M_{t+1} 恢复 M_t ；所以状态更新是增加链接，而不是删除早期观测。

这种表示把“找到”与“读取”分开。解析实体族或关系属于索引查询，打开对应的源文本则是单独的读取操作。关系边帮助智能体找到相连的观测，但支撑这条边的陈述仍保存在原文中。处理时间 τ_i 是图谱唯一的状态轴。原文中的事件日期可以放在 x_i 中并参与回答，但不会产生第二套版本时钟。

3.2 写入记忆

写入遵循式 (1) 中的状态转移：按照原文位置切分文档中的 Episode；从每个 Episode 中抽取实体和关系；将候选身份与已有概念实体族比较；最后把确认的链接和支撑它们的观测一起写入。每条链接都能沿路径回到具体文档片段。

首次提及无法确定实体身份时，Deep-Dream 会先保留多个候选实体族。后续观测和关系邻域提供足够证据后，再合并兼容的实体族或重定向指针。这个操作只修改 F_t 和 G_t ，不修改 O_t 中的观测。因此，暂时拆分可以在之后修正；相反，过早合并可能把两段历史混在同一个检索入口下。

3.3 即时对齐与延迟实体对齐

实验比较两种写入时机，它们使用相同的状态表示。**即时对齐 (Base)** 在每个窗口到达时执行 **Align**；**延迟对齐 (Align+)** 先追加 o_i 和候选链接，等周围窗口处理完后再解析兼容的实体族。两者的区别在于身份决策何时发生，而不是图谱结构或原文记录不同。

延迟对齐在做合并之前使用更多上下文。它可以把兼容候选放在一起处理，减少重复工作，同时保留支撑每次决策的源文本。第 4.2 节的配对结果量化了这种取舍。

3.4 读取记忆

设 $\mathcal{S}_t$ 是 M_t 中全部不可修改的源文本片段。对问题 q ，智能体从 $C_0(q) = \emptyset$ 开始，选择动作

$$a_{k+1} = \rho(q, M_t, C_k(q), u_k) \in (\mathcal{S}_t \setminus C_k(q)) \cup \{\text{stop}\},$$

其中 u_k 是智能体当前的不确定性。如果 a_{k+1} 是一个源文本片段，就打开它并令

$$C_{k+1}(q) = C_k(q) \cup \{a_{k+1}\};$$

如果 $a_{k+1} = \text{stop}$ ，读取过程结束。用归纳法——每一步只把 S_t 中的一个片段加入 C_k ——可得 $C_k(q) \subseteq S_t$ 且 $C_k(q) \subseteq C_{k+1}(q)$ 。这个公式只记录打开源文本的动作；词法、语义、概念和关系查询会更新 u_k ，但不会把片段加入 C_k 。这就是渐进读取的形式化定义；何时停止由策略决定。

提问时，智能体从当前最有用且成本较低的线索——词法、语义、概念或关系——开始，打开对应 Episode 或源文本，在证据不完整时继续扩展：只问一个事实时，可能一段原文就够了；涉及更新或多个文档时，则可能需要沿关系和版本链接继续读取。

我们比较三种读取方式：

1. **固定检索**。只运行一次词法/语义/图检索，把一份排序后的记忆记录和检索片段交给答题模型；列表不能再修改，也不会与源文件核对。
2. **工具辅助读取**。把只读的搜索、概念、关系和片段工具交给答题智能体；它可以多次调用，并用一次结果组织下一次查询，但答题模型拿到的是工具返回的记录。
3. **原文读取**。用索引选择文档组，再打开原始文件、读取精确片段，并且只提交通过原文门禁的片段。

源文本检查器确认引用的标识符确实由工具返回，并且仍然指向原文。它保证引用来源可追溯，但仍需要智能体判断该片段是否真正支持答案。

3.5 为什么这种表示能够保留有用细节

设 Z 是观测对应的潜在实体身份。由于 $\pi_t(M_{t+1}) = M_t$ ，较新的状态包含早期状态，以及新观测和修订后的链接。因此

$$\begin{aligned} H(Z | M_t) - H(Z | M_{t+1}) &= I(Z; M_{t+1} | M_t) \\ &\geq 0. \end{aligned} \quad (2)$$

第一个等式成立是因为 M_t 可以由 M_{t+1} 恢复——这是由保留的版本链接提供的表示不变量，并不是任意图边都能推出的。如果新观测不含有区分 Z 的信息，差值就是零；如果它能区分候选实体族，条件熵就会下降。这是保留状态的结构性保证，不是已经测量得到的熵增益。

对于问题 q ，设 A 是用于定位候选的紧凑记录， E_C 是从候选集合 C 中打开的源文本， Y 是与答案有关的事实。链式法则给出

$$I(Y; A, E_C | Q = q) = I(Y; A | Q = q) + I(Y; E_C | A, Q = q). \quad (3)$$

这就是链式法则。第一项表示定位候选时使用的信息，第二项表示读取源文本后获得的额外信息。Deep-Dream 压缩的是检索描述，而不是事实的唯一副本。

设 R_q 表示相关源文本位于已打开集合 $C_K(q)$ 中，设 V_q 表示最终答案正确，即 $V_q = \{\hat{Y} = Y\}$ 。由全概率公式，

$$\begin{aligned} \Pr[\hat{Y} = Y | q] &= \Pr[R_q | q] \Pr[V_q | R_q, q] \\ &\quad + \Pr[\neg R_q | q] \Pr[V_q | \neg R_q, q] \\ &\geq \Pr[R_q | q] \Pr[V_q | R_q, q]. \end{aligned} \quad (4)$$

概念和关系链接主要影响第一项，原文读取和引用检查影响第二项。这个不等式不是性能估计，只是把正确回答分解为“找到相关证据”和“读取后正确作答”两个环节。




图 2: MemoryAgentBench results for fixed retrieval, memory-tool reading, and source-grounded reading. Source reading is strongest on tasks that combine mentions or updates.

4 实验

我们分别评估两项操作：在历史不断增长且身份可修订的情况下保存记录，以及针对问题读取所需的证据。

4.1 评估设置

我们使用四个公开基准。主要的 MemoryAgentBench (MAB) 评估包含 10 个任务组、59 份文档和 767 道配对题；Align+ 扩展到 14 个任务组、1,074 道题（完整集合为 29 个任务组、3,671 道题）。所有 MAB 分数均由官方评分器¹计算，回答模型为 Kimi-K3。LongMemEval 先写入完整对话集合，再用配对的 $n=25/25/27$ 样本运行三种回答方法。MAB 以百分比报告（100 表示全部正确，0 表示全部错误）；AR 为 *Accurate Retrieval*，TTL 为 *Test-Time Learning*，LRU 为 *Long-Range Understanding*，SF 为 *Selective Forgetting*；MCC 为 *Multi-Class Classification*，Recom 为按 Recall@5 评分的电影推荐，FC-SH/FC-MH 分别为单跳和多跳 FactConsolidation。Recall、 J 、exact-match 和 Overall 均为越高越好，calls、tokens 和 bytes 为成本指标。采样与评审细节见附录 A.3，附录表 4 说明各基准对应存储问题还是读取问题。

4.2 如何存储：更新与实体对齐

LongMemEval 检验完整对话历史写入后，早期陈述和后续修正是否都能被找到。在配对运行中，直接检索由 0.68 升至 0.72，记忆工具阅读由 0.68 升至 0.72，原文支撑阅读由 0.889 升至 0.926 ($n=25/25/27$ ；这些轨迹样本较小，只能作方向性观察)。这些配对运行表明，新旧观测可以由同一读取路径共同访问。独立的 500 题 LongMemEval-S 运行达到 84.60%，回答者和评审均为 Qwen3.7-plus；该协议与表中其他回答者/评审组合不同。

对齐实验检验身份何时被最终确定。即时对齐逐窗口决策，延迟对齐则等待周围证据。在配对写入记录中，每份 MAB 文档的调用由 609 降至 329，每份 LongMemEval 文档由 63.8 降至 22.0。同名重复族在 MAB 上由 340 降至 124，在 LongMemEval 上由 482 降至 99。配对样本中 MCC 和 FC-MH 各提高 3 个百分点，95% 区间为 -7 至 $+13$ （包

¹ 本轮实验固定使用提交 455306d 的评分器。

含零)。这些数据对应一个组合式写入路径，其中同时使用延迟对齐、批处理和并发处理；实际效果是降低构建成本，并为修订身份链接提供更多机会。三臂分解见附录表 5，附录图 6 分别展示成本、重复族和质量变化。

MEME 把历史保留与删除区分开来：100 个 episode 共进行 694 次后任务检查，删除准确率为 0%，级联为 46.34%，缺失为 59.23%。这个零值是当前写入/读取路径的属性：MEME 删除事件要求系统停止返回某条旧事实，同时保留周围历史；测试路径却把删除陈述记录为另一条观测，没有墓碑标记，也没有从实体或关系传播到受影响片段的查询时抑制规则，因此证据虽被保留，仍会被检索。支持删除需要记录删除目标，把不可用状态传播到派生指针，并区分当前查询与历史查询。这个结果精确定位了缺失操作，不能说明仅靠保留来源就实现了遗忘。对应的更新、邻居跳转和删除分解见附录图 8。

4.3 如何读取：渐进式证据检索

图 2 给出分面板结果。面板 (a) 在 Align+ 上约由 33 升至 40 再升至 71；面板 (b) 显示原文路径达到 88.8 AR、52.9 TTL、62.3 LRU 和 80.0 SF，而其他路径的 TTL 仍为 2.6。面板 (c) 在 MCC (46.0) 和 FC-MH (70.0) 上呈现相同优势；面板 (d) 显示 209 道零分题中有 122 道属于 TTL。因而，增益与原文访问以及围绕更新和事实整合的持续取证有关。

三条路径（节 3.4）在答案者获得的内容和追加请求的权限上不同。**固定检索**一次性生成记忆记录和分块的排序列表，不能修改、重新打开或核对。**记忆工具阅读**可以多次发起只读调用，第二次调用可利用第一次返回的实体或关系，但答案者的上下文局限于工具返回的记录，没有来源文件门。**原文支撑阅读**用同一索引选择文档组，再打开原始文件，只把通过来源门的片段交给答案者。因此，第二条路径是在存储记录上的自适应导航，第三条路径则在此基础上增加原文阅读。

逐行结果呈现相同模式：原文阅读在 MCC、FC-MH、MH-QA 和 LongMemEval-S 上最强，而工具阅读主要帮助 DetectiveQA 等任务。这些任务中，第一段看似相关的分块并不够用，智能体必须合并多次提及、追踪更新或核对限定词。固定路径无法请求缺失提及；工具路径可以请求另一条有界记录；原文路径能够检查所选文件并核对措辞。614 题热图和路径协议对比见附录图 5 与附录表 3。

全文参考在文档组适合预算的 614 道题上达到 78.7。原文支撑阅读在相同题目上为 70.8，在扩展的 1,074 题上为 71.0，并且仍可处理超出预算的 460 道题。全文上下文在能够容纳时表现很强，而地址化读取可以在语料超过单一窗口后继续工作。

LoCoMo 在 Mem0 兼容的二元 J 指标下测试跨 Episode 证据（即由语言模型评审判定为正确的答案比例）。Deep-Dream 总体达到 95.19%（单跳 97.38，多跳 93.62，开放域 80.21，时间 95.33），独立的 Qwen3.7-plus 交叉评审在同一答案上给出 94.22%。由于 1,540 行中有 1,529 行早于运行时代码指纹记录，我们将其作为单次诊断；已发表的 Mem0 和 Zep 行保留各自的回答者、评审者和测试流程。多跳与时间结果与设计相符：关系路径连接 Episode，来源观测保留支撑陈述。

一个实际的 LongMemEval 轨迹具体展示了存储结构和读取过程如何衔接。智能体先沿着概念和关系指针跨越两份文档，再打开包含 \$120、\$225、数量 20 和单价 \$7.50 的原文片段，计算出 $120 + 225 + (20 \times 7.50) = 495$ 。七次成功调用显示图结构负责定位候选，原文片段提供算术所需的数值；第八次格式错误并达到步数上限的记录也被保留，便于审计。这个案例用于说明读取过程，不替代总体基准结果。

4.4 与现有记忆系统的比较

表 2 将 Deep-Dream 与 MAB、LoCoMo 和 LongMemEval-S 的已发表结果并列，模型列明确每种配对。在 MAB 行中固定使用 Kimi-K3：固定检索 33.3，迭代记忆工具 40.0，原文阅读 71.0；78.7 的全文行是在文档适合窗口的 614 道题上的同模型参考上限。已发表行保留其原有回答者和评审者，因此只有同模型 MAB 配对构成受控比较。分类复现见附录表 8–10 和 12。绿色行标记近期强模型报告：† 使用 GPT-5-mini/GPT-5，‡ 使用 GPT-4.1-mini 或 GPT-5-mini 并由 GPT-4o-mini 评审，* 使用 Gemini-3 Pro 以及 GPT-OSS-120B 记忆和评审 (Ji et al., 2026; Wang et al., 2026; Latimer et al., 2025)。LongMemEval-S 上，Deep-Dream 的 84.6 (Qwen3.7-plus 回答者和评审者) 低

	Direct retrieval		Tool-assisted reading		Source reading		Source–Direct (Align+)
Task / domain	Base	Align+	Base	Align+	Base	Align+	Source–Direct (Align+)
AR: Accurate Retrieval							
SH-QA	54.0	48.0	84.0	72.0	94.0	92.0	44.0
MH-QA [‡]	–	22.0	–	42.0	–	77.0	55.0
LongMemEval-S*	26.7	41.7	43.3	51.7	90.0	88.3	46.6
EventQA	90.3	89.7	90.7	88.3	98.0	98.0	8.3
TTL: Temporal and Test-time Learning							
MCC, icl_clinic150	4.0	2.0	3.0	2.0	43.0	46.0	44.0
Recom [‡]	–	3.2	–	3.2	–	59.8	56.6
LRU: Long-range Understanding							
∞Bench-Sum [†]	0.0	0.0	28.4	29.8	21.2	0.0	0.0
DetectiveQA	50.0	66.7	50.0	83.3	83.3	83.3	16.6
SF: Selective Forgetting							
FC-SH	68.0	66.0	67.0	63.0	90.0	90.0	24.0
FC-MH	2.0	3.0	4.0	4.0	67.0	70.0	67.0
Overall (n = 767)	30.2	32.4	37.6	40.7	66.9	65.1	32.7
Overall (n=1074, extended)	–	33.3	–	40.0	–	71.0	37.7

表 1: MemoryAgentBench scores (percent). The last column is Source-Direct within Align+; it is reported when both Align+ paths are available. Bold and underlining mark the best and second-best entry within each row.




图 3: Recorded LongMemEval trace (question 2b8f3739): concept tracing exposes four episode pointers across two documents, and semantic retrieval locates the third sales record. Seven successful calls read 120, 225, and 7.50; a malformed eighth response reaches the step limit, after which a separate answerer computes 495. The trace shows graph navigation locating candidates and source spans supplying the arithmetic.

于 MemMachine (93.0)、Hindsight (91.4) 和 Supermemory (85.2); 差距主要集中在会话偏好、时间推理和多会话问题。Deep-Dream 在助手事实、用户事实和知识更新上较强; 这些是下一步读取和更新的目标, 同时保留 MAB 上的原文读取优势以及 LoCoMo 多跳和时间维度的表现。

对于 Infini Memory-A, MAB 行采用其论文报告的四类平均值: AR 为 81.2, TTL 为 51.0, LRU 为 68.6, SF 为 58.0, 总体为 64.7; 不以更细的子任务分数替换这些类别值。

现有系统使用不同的记忆对象: 抽取的原子记忆 (Mem0)、带有效期窗口的情景图 (Zep/Graphiti)、段落图 (HippoRAG-2)、链接笔记 (A-MEM) 或类型化模块 (MIRIX)。Deep-Dream 保持来源片段的权威性, 并以概念和关系作为可修订地址, 使智能体能够在原始文件中核验多次提及的答案。

(a) MemoryAgentBench (official scorer)						
Memory system	Answerer	AR	TTL	LRU	SF	Overall
Full context	GPT-4o	58.1	50.0	54.9	32.5	48.8
Full context	GPT-4o-mini	49.2	48.6	46.2	25.0	42.2
Full context	GPT-4.1-mini	71.8	46.2	49.1	20.5	46.9
Full context	Gemini-2.0-Flash	65.1	46.4	41.6	16.5	42.4
Full context	Claude-3.7-Sonnet	59.7	53.9	62.2	22.5	49.6
Full context ($n=614$)	Kimi-K3	96.8	75.0	65.2	78.0	78.7
BM25 RAG	GPT-4o-mini	60.5	44.5	35.6	25.5	41.5
HippoRAG-2	GPT-4o-mini	65.1	35.8	36.2	29.5	41.6
MIRIX	GPT-4.1-mini	63.0	35.7	40.5	11.5	37.7
MemGPT	GPT-4o-mini	34.3	40.8	22.4	15.5	28.3
Zep	GPT-4o-mini	37.5	37.5	16.2	5.0	24.0
Mem0	GPT-4o-mini	32.6	21.2	20.7	10.0	21.1
Infini Memory-A	GPT-5-mini [†]	81.2	51.0	68.6	58.0	64.7
Deep-Dream / Direct retrieval	Kimi-K3	50.3	2.6	45.9	34.5	33.3
Deep-Dream / Memory-tool agent	Kimi-K3	63.5	2.6	60.4	33.5	40.0
Deep-Dream / Source reading	Kimi-K3	88.8	52.9	62.3	80.0	71.0

(b) LoCoMo J score (%; Mem0 scoring)						
Memory system	Answerer / judge	Single-hop	Multi-hop	Open-domain	Temporal	Weighted
Mem0	GPT-4o-mini	67.13	51.15	72.93	55.51	≈62.14
Mem0 ^g	GPT-4o-mini	65.71	47.19	75.71	58.13	≈61.36
Zep	GPT-4o-mini	61.70	41.35	76.60	49.31	≈56.32
LangMem	GPT-4o-mini	62.23	47.92	71.12	23.43	≈52.08
OpenAI	GPT-4o-mini	63.79	42.92	62.29	21.71	≈51.10
A-Mem*	GPT-4o-mini	39.79	18.85	54.05	49.91	≈38.95
MemMachine	GPT-4.1-mini / GPT-4o-mini [‡]	95.12	88.30	71.88	91.59	91.69
Hindsight	Gemini-3 Pro / GPT-OSS-120B*	86.17	70.83	95.12	83.80	89.61
Deep-Dream (diagnostic)	Kimi-K3	97.38	93.62	80.21	95.33	95.19
Deep-Dream	Qwen3.7-plus / Qwen3.7-plus	96.91	92.91	77.08	93.46	94.22

(c) LongMemEval-S (%)								
Memory system	Answerer / judge	Overall	Sess. pref.	Sess. asst.	Temporal	Multi-sess.	Knowl. upd.	Sess. user
Full context	GPT-4o-mini	55.4	30.0	81.8	36.5	40.6	76.9	81.4
Full context	GPT-4o	60.2	20.0	94.6	45.1	44.3	78.2	81.4
Zep	GPT-4o-mini	63.8	53.3	75.0	54.1	47.4	74.4	92.9
Zep	GPT-4o	71.2	56.7	80.4	62.4	57.9	83.3	92.9
MemMachine	GPT-5-mini [‡]	93.0	93.3	98.2	91.7	87.2	94.9	100.0
Hindsight	Gemini-3 Pro*	91.4	80.0	96.4	91.0	87.2	94.9	97.1
Supermemory	Gemini-3 Pro*	85.2	70.0	98.2	82.0	76.7	89.7	98.6
Deep-Dream	Qwen3.7-plus / Qwen3.7-plus	84.6	53.3	100.0	84.2	74.4	91.0	98.6

表 2: Results for Deep-Dream and published memory systems on MemoryAgentBench, LoCoMo, and LongMemEval-S. Each row retains its answerer, judge, subset, and evaluation setting. The Deep-Dream LoCoMo row is a single-run diagnostic; its legacy-fingerprint details are in the appendix. Bold marks each column’s maximum among the reported comparable rows; the single-run diagnostic row is intentionally unbolded; the Infini Memory-A row uses the category averages reported in its paper.

4.5 检索与证据诊断

我们在相同的 210 道题上重放四种索引：对原始 Episode 使用关键词 (BM25)，再依次加入语义链接、图邻居和关系链接。Recall-any@10 询问前十项中是否出现至少一条相关项；Recall-all@10 询问是否出现全部相关项。Recall-any@10 分别为 72.38、72.38、71.43 和 72.38%；每个配对差异都落在基于同一重放计算的 ± 2.4 个百分点 95% bootstrap 等价界内，其他指标也没有稳定变化。因此，重放没有证据表明图链接单独提升离线召回；它只说明离线检索，而在线阶段实际使用了图的导航作用——在原文阅读前选择文档组、版本和关系链接——并未对该作用做消融。

附录图 7 报告相应的调用和 token 成本。原文支撑阅读由于需要核验并扩展证据，调用更多；但在需要多次提及或更新的问题上也产生最强答案。

5 分析与局限

核心主张是校准存储与读取之间的关系。来源片段是被保存的观测；身份族、关系或版本是推断得到的访问结构；检索到的段落则是智能体主动选择检查的内容。把这些类别

分开可以支持修订，但不能保证身份正确，也不能保证读到的段落蕴含答案。来源门只验证来源，不验证身份或蕴含关系。

这种存储选择在提出具体问题之前就决定了信息能否保留。只保存摘要会提前压缩历史，后来的问题可能需要摘要中被省略的限定条件、旧状态或原始措辞。Deep-Dream 保留来源观测，把图结构只用于定位，因此当前值仍然可以回到产生它的历史观测，而不是覆盖这些观测。

延迟对齐让这种表示可以修订。过早合并可能把两个同名的人放在同一个地址下，污染双方的历史；暂时拆分只增加候选，之后可以通过重定向链接来修正。因此，入库实验说明的是成本和可修订性变化，并不能证明当前身份标签已经完全正确。版本链接还保留了当前值的形成过程：处理时间排列存储状态，原文中提到的日期仍属于观测内容。查询可以要求最新值，也可以要求较早的值，而不必改写历史记录。

Align+ 使写入调用减少 46–65%，但其中同时包含延迟对齐、批处理和并行处理。同名族在 MemoryAgentBench 上由 340 降至 124，在 LongMemEval 上由 482 降至 99。同名重复代理不是身份标签，配对质量区间为 -7 至 $+13$ 个百分点。MCC 和 FC-MH 各提高 3 个百分点，95% 区间为 -7 至 $+13$ ，因此这些结果说明的是构建成本与可修订性的权衡，而不是身份准确率提升。熵论证还以固定目标和保留前驱状态为条件。

MAB 路径比较中，固定检索、记忆工具和原文阅读在 1,074 道题上的 Kimi-K3 得分分别为 33.3%、40.0% 和 71.0%。三条完整路径在工具、原文访问、迭代方式、证据处理和预算上均有差异，因此不能据此单独分离身份层或图结构的作用。原文阅读在相同的 614 题上为 70.8%，全文上下文为 78.7%；另有 460 道题超出全文预算。离线图消融没有稳定收益。即使活动上下文较小，反复检索也可能提高成本；来源检查也不能解决停止时机或答案支持问题。

MEME 在 694 次后任务检查中的 100 个删除检查上准确率为 0%，级联和缺失准确率分别为 46.34% 和 59.23%。该路径没有目标级墓碑标记和传播式抑制。LongMemEval-S 在 Qwen3.7-plus 同时担任回答者和评审时为 84.6%，协议与其他结果不同。LoCoMo 的 95.19% 和 94.22% 是历史单次诊断，其中 1,540 行有 1,529 行早于运行时代码指纹记录。这些结果要求直接标注身份、检查蕴含关系，并开展资源匹配的读取实验。

尚未测量的内容。 通过来源检查的段落仍可能与问题无关，正确链接的身份也可能需要另一份文档。当前实验没有带标签的身份决策、蕴含标注或资源匹配的停止曲线，删除结果也没有测试完整的抑制设计。后续评估应标注候选合并，在读取策略之间固定调用数和 token 数，并分别评价当前查询与历史查询。

section 结论

labelsec:conclusion

长期记忆有两个相互关联的问题：如何在实体和事实不断变化时保存不断增长的记录，以及如何在上下文窗口有限时只读取当前问题需要的证据。Deep-Dream 通过保留文档片段作为事实记录，并把概念、关系、观测、版本和候选身份作为可修订的访问结构，回答了记忆如何存储的问题。读取时，智能体沿着这些结构打开相应的原文，比较早期和后续观测，并在证据足够时停止。

这种分工让每一部分承担清晰的责任。图结构缩小搜索范围，但本身不授权答案；原文片段提供具体措辞，但单独不能解决身份判断；智能体决定是否还需要查看另一份文档、关系或版本。MAB 中的结果因此体现了完整读取路径的差异，而不是单独的图结构或原文消融。写入实验也表明，延迟对齐和并行处理可以降低构建成本并减少重复实体族，但目前没有测得一致的对齐质量提升。全文上下文在匹配题目上仍然更强，而 MEME 结果说明，保留历史记录并不等于已经规定了何时应当抑制历史。

正文中的实际轨迹进一步说明了这种分工：概念和关系负责定位候选，原文片段提供计算所需的具体数值。

本文的核心贡献，是把记忆存储和记忆读取分成两个可以分别改进、分别审计的问题：原文保留事实，概念、关系和版本提供可修订的索引，智能体自主决定读取路径和深度。后续研究可以在此基础上标注身份判断，使用相同资源评估蕴含和停止策略，并加入明确的当前状态、历史状态和删除抑制规则。

道德声明

本研究使用公开的基准数据和已记录的软件运行结果，不收集个人数据，不涉及人类受试者，也不对具体个人作出决策。文中的案例仅用于评估记忆检索和证据追踪，并遵守各基准数据集和软件来源的许可与署名要求。

可复现性声明

随论文发布的补充材料包含运行清单、配置、提示词、逐题输出、重算脚本和完整性哈希，可用于重现正文表格。附录 A.1 说明产物账本，其余附录给出抽样范围、答题模型与评审模型、对齐实验和审计细节。所有结果均从冻结产物重新生成，而不是手工录入。

AI 使用声明

在本工作中，我们使用生成式 AI 工具（包括 OpenAI Codex）起草、重构并编辑手稿；准备中文阅读版；检索相关文献与书目信息；协助分析与绘图代码；以及表述架构的信息论解释，包括数学主张及其论证（渐进式实体对齐、检索——证据分离，以及依赖查询的读取预算），也包括把上下文解读为工作集、把记忆存储解读为被寻址结构的内存层级框架表述。生成式图像工具用于创建和修改解释性框架图。我们未使用生成式 AI 工具产生所报告的结果：本流程未创建任何合成评测数据集，所有报告的基准分数均取自有记录的实验运行，而非生成的估计。

我们已复核全部 AI 协助工作。报告的数值由随论文发布重算脚本从冻结运行产物重新生成，而非转录自 AI 输出；AI 建议的参考文献均与原始出版物核对；数学表述均附其假设条件并与实测值挂钩，而非无条件定理。AI 协助不构成独立的证明验证或实证校验。

我们对本工作的最终内容负责，包括在生成式 AI 协助下产生的文本、主张与产物。

REFERENCES

- Herman Chernoff. A measure of asymptotic efficiency for tests of a hypothesis based on the sum of observations. *The Annals of Mathematical Statistics*, 23(4):493–507, 1952. doi: 10.1214/aoms/1177729330. URL <https://doi.org/10.1214/aoms/1177729330>.
- Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready ai agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025. URL <https://arxiv.org/abs/2504.19413>.
- Mingxuan Du, Benfeng Xu, Chiwei Zhu, Shaohan Wang, Pengyu Wang, Xiaorui Wang, and Zhendong Mao. A-RAG: Scaling agentic retrieval-augmented generation via hierarchical retrieval interfaces. *arXiv preprint arXiv:2602.03442*, 2026. URL <https://arxiv.org/abs/2602.03442>.
- Ivan P. Fellegi and Alan B. Sunter. A theory for record linkage. *Journal of the American Statistical Association*, 64(328):1183–1210, 1969. doi: 10.1080/01621459.1969.10501049. URL <https://doi.org/10.1080/01621459.1969.10501049>.
- Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. Enabling large language models to generate text with citations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 6465–6488, Singapore, 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.398. URL <https://aclanthology.org/2023.emnlp-main.398/>.
- Bernal Jiménez Gutiérrez, Yiheng Shu, Weijian Qi, Sizhe Zhou, and Yu Su. From rag to memory: Non-parametric continual learning for large language models. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267

- of *Proceedings of Machine Learning Research*, pp. 21497–21515. PMLR, 2025. URL <https://proceedings.mlr.press/v267/gutierrez25a.html>.
- Yuanzhe Hu, Yu Wang, and Julian McAuley. Evaluating memory in llm agents via incremental multi-turn interactions. *arXiv preprint arXiv:2507.05257*, 2025. URL <https://arxiv.org/abs/2507.05257>.
- Suozhao Ji, Baodong Wu, Zehao Wang, Lei Xia, Qingping Li, Ruisong Wang, Wenbo Ding, Zhenhua Zhu, Boxun Li, Guohao Dai, and Yu Wang. Infini memory: Maintainable topic documents for long-term llm agent memory. *arXiv preprint arXiv:2606.10677*, 2026. URL <https://arxiv.org/abs/2606.10677>.
- Seokwon Jung, Alexander Rubinstein, Arnas Uselis, Sangdoo Yun, and Seong Joon Oh. Meme: Multi-entity & evolving memory evaluation. *arXiv preprint arXiv:2605.12477*, 2026. URL <https://arxiv.org/abs/2605.12477>.
- Chris Latimer, Nicolo Boschi, Andrew Neeser, Chris Bartholomew, Gaurav Srivastava, Xuan Wang, and Naren Ramakrishnan. Hindsight is 20/20: Building agent memory that retains, recalls, and reflects. *arXiv preprint arXiv:2512.12818*, 2025. URL <https://arxiv.org/abs/2512.12818>.
- Patrick S. H. Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pp. 9459–9474, 2020. URL <https://arxiv.org/abs/2005.11401>.
- Yifei Li, Weidong Guo, Lingling Zhang, Rongman Xu, Muye Huang, Hui Liu, Lijiao Xu, Yu Xu, and Jun Liu. Locomo-plus: Beyond-factual cognitive memory evaluation framework for LLM agents. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 25085–25100, San Diego, California, United States, July 2026. Association for Computational Linguistics. doi: 10.18653/v1/2026.acl-long.1150. URL <https://aclanthology.org/2026.acl-long.1150/>.
- Hai Lin, Hoilam Pao, Shaoxiong Zhan, and Hai-Tao Zheng. Model-native computing architecture: Envisioning future system architecture through the lens of computer architecture. *arXiv preprint arXiv:2606.00288*, 2026. URL <https://arxiv.org/abs/2606.00288>.
- Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Parandekar, Danqi Chen, and Percy Liang. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. doi: 10.1162/tacl_a_00638. URL <https://arxiv.org/abs/2307.03172>.
- Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 13851–13870, Bangkok, Thailand, 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.acl-long.747. URL <https://aclanthology.org/2024.acl-long.747/>.
- Vasilije Markovic, Lazar Obradovic, Laszlo Hajdu, and Jovan Pavlovic. Optimizing the interface between knowledge graphs and llms for complex reasoning. *arXiv preprint arXiv:2505.24478*, 2025. URL <https://arxiv.org/abs/2505.24478>.
- Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. Memgpt: Towards llms as operating systems. *arXiv preprint arXiv:2310.08560*, 2023. URL <https://arxiv.org/abs/2310.08560>.

- Hubert Ramsauer, Bernhard Schöfl, Johannes Lehner, Philipp Seidl, Michael Widrich, Lukas Gruber, Markus Holzleitner, Thomas Adler, David Kreil, Michael K. Kopp, Günter Klambauer, Johannes Brandstetter, and Sepp Hochreiter. Hopfield networks is all you need. In *International Conference on Learning Representations*, 2021. URL <https://arxiv.org/abs/2008.02217>.
- Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. *arXiv preprint arXiv:2501.13956*, 2025. URL <https://arxiv.org/abs/2501.13956>.
- Claude E. Shannon. Coding theorems for a discrete source with a fidelity criterion. In *IRE National Convention Record*, volume 7, pp. 142–163, 1959. URL <https://ieeexplore.ieee.org/document/5311476>.
- Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew Hausknecht. Alfworld: Aligning text and embodied environments for interactive learning. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=0IOX0YcCdTn>. ICLR 2021.
- Naftali Tishby, Fernando C. Pereira, and William Bialek. The information bottleneck method. *arXiv preprint physics/0004057*, 2000. URL <https://arxiv.org/abs/physics/0004057>.
- Shu Wang, Edwin Yu, Oscar Love, Tom Zhang, Tom Wong, Steve Scargall, and Charles Fan. Memmachine: A ground-truth-preserving memory system for personalized ai agents. *arXiv preprint arXiv:2604.04853*, 2026. URL <https://arxiv.org/abs/2604.04853>.
- Yu Wang and Xi Chen. Mirix: Multi-agent memory system for llm-based agents. *arXiv preprint arXiv:2507.07957*, 2025. URL <https://arxiv.org/abs/2507.07957>.
- Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. Longmemeval: Benchmarking chat assistants on long-term interactive memory. In *International Conference on Learning Representations*, 2025. URL https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html. ICLR 2025.
- Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-mem: Agentic memory for llm agents. In *Advances in Neural Information Processing Systems*, volume 38, 2025. doi: 10.52202/085713-0593. URL https://proceedings.neurips.cc/paper_files/paper/2025/hash/19909c36f51abc4856b4560aff3d36d6-Abstract-Conference.html.
- Terry Yue Zhuo, Minh Chien Vu, Jenny Chim, Han Hu, Wenhao Yu, Ratnadira Widayarsi, et al. Bigcodebench: Benchmarking code generation with diverse function calls and complex instructions. In *International Conference on Learning Representations*, 2025. URL https://proceedings.iclr.cc/paper_files/paper/2025/hash/a6a90bcc2aa470c3871b2d39a67d26e8-Abstract-Conference.html. ICLR 2025.




图 4: Deep-Dream 的文档优先时序概念图谱。多份文档保留各自的会话片段，并通过共享的概念族与关系边连接。选中一个族会暴露其按观测时间排列的版本链，以及每次修订的精确源跨度；不确定的匹配可以先保持分离，等到后续内容与关系上下文到达时再收敛。

A 可复现性与审计细节

A.1 工件账本

机器可读账本由发布的账本脚本与重算脚本生成。它记录论文所引每一次运行的源摘要、数据集与逐题 JSONL SHA-256 值，并在投稿冻结时重新生成、与脚本输出逐字节比对。当前账本覆盖 MemoryAgentBench 各轨道（两代引擎 × 三条答案路径、commit 455306d 处的官方评分器、一致的 `entity2id` 指纹）、LongMemEval 整批对话写入后的配对运行与 500 题运行、LoCoMo-1986/1540 及 K3 作答诊断、LoCoMo-Plus-401 (Li et al., 2026)、X7 通道诊断、源扩展诊断、修复后的预算前沿重放、MEME、BigCodeBench (Zhuo et al., 2025) 与 ALFWorld (Shridhar et al., 2021)。每次运行的清单记录数据集与提示词来源、模型标识符、工具观测、证据 ID、延迟、退出状态与代码/运行时哈希；未通过完整性检查的结果与负面结果均予保留而非丢弃。账本生成与重算脚本随发布的补充材料一同提供；补充材料对体积过大、无法再分发的输入（原始智能体轨迹、库快照与 LongMemEval-S 数据集文件）逐一钉住 SHA-256，在完整产物树上两个脚本可逐字节再生账本与冻结重算值。

发布的补充材料包含论文所引每次运行的机器可读清单（数据集、提示词、模型与运行时来源）、逐题分数与答案、运行时哈希，以及把每个随包文件对照账本核验的自校验脚本。论文在每个结果旁报告数据集、模型、评审、子集与完整性状态，使比较保持可审计，同时不暴露机器特定的存储位置。

图 5 在同一批 614 道题上比较四条读取路径。Overall 从固定检索的 38.6 提高到工具读取的 44.6，再提高到原文读取的 70.8；完整上下文参照为 78.7。热力图解释了差距：原文读取的 AR 为 95.0、SF 为 80.0，接近或超过完整上下文，但 TTL 只有 46.0，而完整上下文为 75.0。因此，原文读取在不装入全部语料的情况下恢复了大部分检索和选择性遗忘能力，但更新密集型 TTL 仍需要更强的时序处理。图 6 将 Align+ 的整体变化拆成可观察的结果。面板 (a) 显示 MAB 入库调用从 609 降至 329，LongMemEval 从 63.8 降至 22.0；面板 (b) 显示重复实体族分别从 340 降至 124、从 482 降至 99。面板 (c) 中 MCC 和 FC-MH 都提高了 3 个百分点，配对 95% 区间为 -7 到 +13 个百分点。图中支持构建成本和实体整合方面的收益，同时抽样质量保持相近；由于多个实现改动同时生效，它不是单组件消融。压缩后的读取轨迹见正文图 3。发布的实验材料保留完整的工具调用 JSON、时间戳和格式错误后的重试记录，便于审计。




图 5: 同模型完整上下文参照覆盖的 $n=614$ 题上的问题对齐 (Kimi-K3 作答; 官方宏平均评分器)。(a) 带边缘 95% bootstrap 区间的 Overall 分数; 原文读取方式低于参照 7.9 个百分点 [95% CI -11.9, -3.9]。(b) 域画像: 参照的领先集中在 TTL, 而原文读取方式在 AR、LRU、SF 上与参照持平或反超。




图 6: 捆绑的 Base→Align+ 修订的配对构建诊断。(a) 入库调用与同名重复实体族在记录在案的 MAB 与 LongMemEval 交集上下降。(b) 配对的 MCC 与 FC-MH 切片各上升 3 个百分点; 区间保留, 因为这是捆绑比较而非组件消融。

A.2 版本溯源与对齐 A/B 研究

随附的证据包补充了一项完整的三臂对齐研究 (LongMemEval-S): 三个文档组 (42+49+46 份文档, 每臂 137 份文档)、先写入全部文档、同一 Kimi-K3 端点。臂 A 为不带批量候选检查的基线; B1 启用批量候选检查; B2 额外启用修订后的收敛实现 (并行对齐、推迟的非破坏性合并, 以及最后一致性检查)。保存的 B1 与 B2 服务配置逐字节相同; 二者的差异在运行时代码与 B2 开关上, 因此臂分配从清单与代码快照读出, 而不是从文件名推断。该研究的统计功效面向效率与整合而非质量: 每个文档组在每条评测轨道上只贡献一道题。

另一项 LME Base/Align+ 引擎差异 (初始/修订实现) 是从 commit 73d9c5e 到 8fa9651 的事后重建。后者还包含四项吞吐修复, 因此仅凭它无法确定 Align+ 运行中各时点哪些修复处于生效状态。我们以清单内嵌的流水线配置、运行时策略哈希与技能哈希为准; 重建的差异只是未提交代码的溯源材料, 并不是“每项后来的修复从首次修订运行起就已生效”的主张。

A.3 MEMORYAGENTBENCH 抽样框与污染说明

抽样子集按发布账本中记录的固定任务组清单抽取: 10 个任务组、59 份文档上的 767 题配对样本, 并在 Align+ 引擎上原地扩展四个任务组 (RULER-421K 多跳问答 100 题; 完整 Redial 推荐语料 200 题; 再加一个 DetectiveQA 任务组 6 题; 再加一个 ∞ Bench-Sum 任务组 1 题) 至 14 个任务组上的 1,074 题; 完整基准为 29 个任务、3,671 题。四种能力全部覆盖; 扩展后仍有 17 个任务未被抽样。配对样本及其 entity2id 指纹为全部六次运行 (三条路径 × 两代) 共享; 307 道扩展题仅存在于 Align+; 两个大型扩展文档组 (190 万与 570 万字符) 超出完整上下文参照 1,042,576 字符的严格预算, 因此参照覆盖为 1,074 题中的 614 题。参照使用中性提示词档案; 同一次运行的 normalized-v1

属性	直接检索	工具辅助读取	原文读取
源访问	一次排序结果	Episode/会话载荷	选中文档原文
工具	无	记忆工具	scope、grep、脚本
答题模型	Kimi-K3	Kimi-K3	Kimi-K3
循环	无	多次只读调用	多次读取并核对
每题成本	27.5k tokens, 1.0 LLM calls	43.2k tokens, 6.5 LLM calls	328.6k tokens, 10.2 LLM calls

表 3: 三种读取方式的差异。原文读取路径增加确定性的来源检查，确认返回 ID 指向原文位置；最终仍由 Kimi-K3 作答；三条路径共享冻结库、问题流与官方评分器。

主线	能力	基准与观测量	口径与边界
存	无损积累与可修订身份	LongMemEval 全量写入配对运行 ($n=25/25/27$) 与 500 题 LME-S 运行检验旧陈述与后来更正是否同时可达; Base/Align+ 配对运行度量同名重复族 (MAB 上 340→124、LME 上 482→99) 与入库调用 (每 MAB 文档 609→329; 每 LME 文档 63.8→22.0), MCC/FC-MH 增量的区间包含零。	MEME: 100 个会话片段上删除真实准确率 0% (694 项事后检查); 级联与缺失真实准确率 46.34/59.23; 尚无查询时删除抑制。
取	智能体自主寻址	MemoryAgentBench 在同一 767/3,671 题配对样本 (29 个任务组中的 8 个) 上比较一次性固定检索、多次只读工具调用与带引用检查的原文读取, 并有 Align+ 扩展到 1,074 题; LoCoMo-1540 二值 J 区分单跳、多跳、时序与开放域问题。	已发表 Mem0/Zep 行使用不同的答题模型、评审与评分规则版本, 仅作背景; 通道重放是离线等价界 (± 2.4 个百分点, 95% bootstrap), 不是在线消融。

表 4: 两个研究问题及其测量。每行把基准按所检验的主线分组, 并相邻给出口径与已披露边界。

档案在其自身的 607 题覆盖上得 46.0 分——这是账本中保留的提示词敏感性痕迹, 不作为参照使用。文档组长度是异质的, 并在跨系统单元格领先的场合均予披露: 两个事实整合 (FactConsolidation) 文档组是 6K 变体 (各 26,157 字符); 32K/64K/262K 的 FC 变体 (13.6 万–110 万字符) 与其他未抽样文档组因预算被舍弃, 全部连同上下文大小列于发布账本的子集块中; EventQA 按 64K/128K/完整文档组抽样, 而非只取已发表的全本均值; LRU 域有 $n=7$ 道配对题与 14 道扩展题 (∞ Bench-Sum 先 1 后 2, DetectiveQA 先 6 后 12), 因此 LRU 单元格是方向性的。MAB 源语料是公开的; 答题模型的预训练是否见过它们无法排除、也无法事后度量, 且每一行跨系统表格都声明自己的答题模型、评审与子集。

A.4 调整 OVERALL 的推导

配对样本漏掉了两个对所有人都得分很低的任务——AR 的 MH-QA 与 TTL 的推荐——早期草稿用插补处理: 代入已发表的非全上下文参考值 (推荐 ≈ 13 、MH-QA ≈ 60) 后, 调整 Overall 为 ≈ 59.0 , 而配对样本口径的原始值为 65.1, 敏感性下的区间为 59–61。扩展取代了插补: 两个任务现在都在 Align+ 上直接测得 (读取原文 MH-QA 77.0、推荐 59.8; 表 1), 扩展 Overall 为 71.0, 两个任务都进入了聚合。扩展样本的构成仍与完整基准不同 (17 个任务未抽样), 因此我们继续只陈述原始值、绝不做跨样本口径的相减; 插补估计在此保留, 作为发布账本的溯源材料。

A.5 各路径提示词与配置

所有路径都用 Kimi-K3 作答, 提示词逐字存档于附录 A.1 所列的运行清单与代码快照中; 发布的补充材料完整重印它们。Base→Align+ 的引擎配置差异如下: 最大输出 token 16,384→32,768; 可用上下文窗口 32k→262,144; 重试 2→5; 超时 300s→1,200s; Align+ 启用绝对路径持久化。直接检索做一次融合检索调用与一次作答调用; 工具辅助读取会多次调用只读工具; 原文读取智能体物化一个文档组、读取并验证源文件, 且只提交通过引用检查的跨度。

图 7 将答案质量与运行成本对应起来。面板 (a) 中, 固定检索的均值到 p95 延迟为 31.0–99.3 秒, 工具读取为 65.9–172.8 秒, 原文读取为 95.0–451.7 秒; 原文路径每题使

臂	对齐修订	调用/文档	总 token/文档	实体重定向	重复组
A	基线	68.4	145,378	0	8
B1	批量候选检查	24.2	108,467	1	12
B2	批量检查 + 最后一致性检查	29.4	111,853	245	6

表 5: 每臂 137 份 LongMemEval-S 文档上的三臂对齐研究。B1 提供大幅效率下降; B2 在最后一致性检查上比 B1 多花约 3% 的 token, 是唯一具有实质非破坏性族重定向的臂, 降低了同名重复组。质量切片太小, 不足以做质量主张。B1 与 B2 使用同一份保存的服务配置; B2 的差别在运行时实现与对齐开关。




图 7: 冻结产物的运行点诊断 (Align+ 引擎; 面板 a 覆盖全部 1,074 题)。(a) 答案延迟的均值到 p95, 标注 token 数与调用数; (b) 配对的 Base→Align+ 入库成本; (c) 有效的固定排序检索预算前沿; (d) $k=10$ 处的仅源文档通道重放。

用 10.2 次调用和 328.6k token。面板 (b) 说明延迟对齐的运行收益: 调用从 609 降至 329、从 64 降至 22, token 从 1,456k 降至 1,191k、从 139k 降至 112k。面板 (c) 直接显示预算取舍: k 从 1 增加到 20 时, Recall-any 从 26.2% 升至 81.9%, Recall-all 从 14.3% 升至 59.5%, 平均载荷从 0.2 增加到 3.6 kB。面板 (d) 在词法、语义、邻居和关系通道之间基本平坦, 说明主要收益来自扩展读取路径, 而不是某一个离线通道。

A.6 附加定量诊断

账本还包含类型级更新分数、一次受控的源扩展重放, 以及 MEME 删除边界。图 8 报告这些量, 并让样本量与开发集限制保持可见。




图 8: 来自冻结账本的额外定量诊断。(a) 配对 Base/Align+ 轨道的 LongMemEval 类型分数; 这些方向性样本 $n=25/25/27$, 以粗略百分比显示。(b) 105 个历史错误案例上的源扩展召回对响应载荷; 这是开发诊断, 不是留出测试。(c) 带任务特定分母的 MEME 真实任务准确率, 暴露 0% 的删除边界。

图 8 提供了三项机制检查。面板 (a) 中最清楚的 LongMemEval 变化出现在多会话访问: 原文读取从 Base 的 85.7% 提高到 Align+ 的 100%, 知识更新和时序分数仍为 100%; 这与跨会话整合改善相符, 而不是所有类别一起变化。面板 (b) 中, 加入一跳和两跳邻居后, Recall-any 从 70.5% 提高到 84.8% 和 89.5%, Recall-all 从 52.4% 提高到 65.7% 和 73.3%, 载荷增加约 0.4–0.5 kB。面板 (c) 将任务语义分开: 实体解析 100%、跟踪 97%、聚合 80%、缺失 59.2%、级联 46.3%、删除 0%。这说明图结构有助于定位相关证据, 而删除仍需独立的抑制操作。

A.7 载体参照 (BigCodeBENCH (ZHUO ET AL., 2025)、ALFWORLD (SHRIDHAR ET AL., 2021))

BigCodeBench: 0.4859 完成率 / 0.2838 困难 pass@1 (校准切分)。ALFWorld: 0.9786 同分布 / 0.9851 异分布成功率。两者都是对记忆不敏感的智能体载体回归测试: 它们锚定智能体载体能正确执行任务, 而不与记忆基准横向比较。

A.8 MAB 入库清单缺口

Base 与 Align+ 的 MAB 入库运行共享 45 份文档的配对交集。在某一代中缺失清单的文档被排除在每文档效率比之外, 因此效率比只在交集上计算 (每文档调用 609→329, -46%); token 比使用同一交集。题目级结果不受影响: 全部 767 道配对题在两代中都对着冻结库运行, 307 道扩展题只在 Align+ 引擎上运行, 因此入库成本比仍定义在配对交集上。

A.9 预算前沿

早期的一次 depth-10 对 depth-20 重放作为一项完整性发现被保留: 其前缀不变量在全部 210 题上失败 (primary_result_invariant_violations=210), 因此它不用于任何正面主张。修复后的设计对每个查询以最大深度只运行一次检索, 并把固定的排序切到 $k \in \{1, 3, 5, 10, 20\}$; 前缀单调性因此按构造成立 (零违例), 前沿从 $k=1$ 到 $k=20$ 单调上升, 每个 k 的百分位 bootstrap 置信区间从冻结的重放产物重新计算。

A.10 X7 通道消融细节

A.11 测试条件说明

原始 LoCoMo token-F1 轨道含 1,986 题与五个类别。Mem0 兼容轨道含 1,540 题与四个类别。LongMemEval-S 含 500 题; 整批写入后的配对运行使用节 4.1 所述的 $n=25/25/27$ 。MEME 的 100 个会话片段产生异质的任务数 (所引运行中

表 6: X7 来源记录消融: 210 题检查集上的离线检索重放。臂 1–4 构成干净的通道消融: 只有 `enabled_channels` 不同, 因此任何召回差异都可归因于该通道集合。臂 5 (引用核对智能体, 开启检查) 与臂 6 (未被检索到的证据, 放宽检查) 复用臂 4 的五通道排序, 与臂 4 检索一致; 它们的区分列 (问答准确率、无支撑答案率、平均证据 token) 需要 LLM 智能体运行, 尚待完成。引用检查流程已离线验证: 开启检查时提交一个未浮现的对话轮会被拒绝; 放宽检查时同一提交被接受 (`plumbing_ok=true`)。在部署的 MAB 运行中, 检查按设计触发: 14/1074 questions in the deployed v2 skill-agent run had an evidence submission rejected as unsurfaced (9/767 in v1); 11 of the 14 resubmitted tool-surfaced evidence inside the loop and the remaining 3 ended at the step cap and were answered from tool-surfaced context; zero rejections on the LME runs。Bootstrap 置信区间: 2,000 次重采样, 95%。

臂 通道 (累加)	Recall-any@10 [95% CI]	Recall-all@10 [95% CI]	平均字节 @10
1 raw-doc + episode-bm25	72.38 [66.67, 78.57]	51.43 [44.76, 58.10]	1833
2 + semantic-provenance	72.38 [66.67, 78.57]	51.43 [44.76, 58.10]	1841
3 + graph-neighbor	71.43 [65.70, 77.62]	50.95 [44.29, 57.62]	1845
4 + relation-evidence (full 5)	72.38 [66.65, 78.57]	51.90 [45.24, 58.58]	1847

基准	协议	分数	答题 / 评审
LongMemEval-S (500)	抽样, $n=500$	84.60	Qwen3.7-plus 作答; Qwen3.7-plus 评审
LongMemEval, 直接检索	配对, $n=25$	0.68 $\rightarrow$ 0.72	Kimi-K3 作答
LongMemEval, 工具辅助读取	配对, $n=25$	0.68 $\rightarrow$ 0.72	Kimi-K3 作答
LongMemEval, 原文读取	配对, $n=27$	0.889 $\rightarrow$ 0.926	Kimi-K3; 自评审
LoCoMo-1540	Mem0 J 评分	95.19	Kimi-K3; 作答 + 评审; $n=1$
LoCoMo-1540 (同一批答案)	交叉评审	94.22	Qwen3.7-plus; 一致率 98.51%

表 7: 其他基准在各自测试流程下的结果; 每行列出答题模型和评审模型。LoCoMo 运行与 Mem0 已发表的 J 有两处明示差异——单次运行对 10 次运行均值 $\pm$ 标准差, 以及作答/评审模型——并携带已披露的遗留指纹注意事项; 这些条件同时列出, 便于复核比较。LME 原文读取轨道多出的两题来自其会话证据规则; 比较只在同一测试轨道内进行。

ER/Agg/Tr/Del/Cas/Abs 的事后检查数为 100/100/100/100/164/130)。raw 分数与 real 分数不可互换。

A.12 保留的完整性失败

附录 A.9 的深度重放报告 `primary_result_invariant_violations=210` 且 `passed=false`。MEME 删除结果为 0% 的 real 准确率。X7 通道消融是零结果, 以等价界的形式报告而非丢弃。 ∞ Bench-Sum 的 $n=1$ 翻转直接使 Align+ Overall 损失 2.7 分 (Base $\rightarrow$ Align+ 净差距为 1.8 分), 并在每处比较中披露。LongMemEval 上直接检索与工具辅助读取打平的结果虽然对记忆工具路径不利, 仍予报告。这些记录保持可见, 因为一篇可审计的记忆论文应当同时暴露失败与零结果的机制, 而不只是成功的机制。

A.13 外部比较协议

Mem0 原论文报告 LoCoMo 类别级 F1、BLEU-1 与一个二值 J : GPT-4o-mini 评审把每个答案标为 CORRECT 或 WRONG, 得分即判定为 CORRECT 的百分比 (10 次独立运行的均值 $\pm$ 标准差)。Zep 原论文报告 DMR 与 LongMemEval, 答题模型为 GPT-4o 系列。我们不在自己的协议下重跑这些系统, 而是在下方逐字重印其已发表表格 (表 8–10) 作为不同测试流程下的参考结果。因篇幅从正文表格中省略的 Mem0 确定性 token 重叠指标重印于表 12。

K3 替换行。 放入 Mem0 J 列内的唯一一行 Deep-Dream J , 是用 Mem0 原样的二值评分方式、以 Kimi-K3 同时替换 GPT-4o-mini 的答题与评审角色

得到的——唯一的改动就是模型。同模型 K3 评审下得 95.19% (S/M/O/T 为 97.38/93.62/80.21/95.33)；同一批 K3 答案经独立的 Qwen3.7-plus 交叉评审得 94.22% (96.91/92.91/77.08/93.46；交叉评审一致率 98.51%)。相对 Mem0 已发表 J 的两处差异照例明示：单次运行而非 10 次运行均值 $\pm$ 标准差；模型为 Kimi-K3 而非 GPT-4o-mini。我们额外披露一条完整性注意事项：该运行清单带有 `diagnostic_override={kind:legacy-missing-runtime-code-fingerprint, formal_claim_allowed:false}`，因为 1,540 行答案中有 1,529 行来自早于运行时代码指纹机制的遗留源运行 (legacy-source-run)。答案本身未变 (`answer_rows_unchanged=true`，答案 SHA-256 为 76af5772)，且逐题 JSONL 在全部 2,063 行上都带 `runtime_code_sha256` (3 个不同哈希：2fa32774 覆盖 2,019 行、36b45933 覆盖 33 行、42af1bac 覆盖 11 行)，数据集 SHA-256 (79fa87e9) 与库快照 (cf2e76b8) 与 Qwen 作答运行相同，Mem0 二值评审提示词也相同 (仓库 `mem0ai/memory-benchmarks`，commit 4b61c5d，模式 `unified-no-evidence-exact-direct`)。因此我们把 95.19% 报告为诊断性交叉评审结果，而不是指纹完备的正式条目。

更严格的受控比较——冻结相同的答题模型、评审模型、提示词、温度、证据预算、数据集修订版本与 Graphiti/Zep 实现 commit——仍是通向共享榜单的唯一途径；但既然已发表数字被直接引用，它不再是投稿的硬性门槛。

A.14 存储与读取的形式化性质

本节把存储和读取的主张写成可检查的形式。第一个结果是版本化、只增存储的结构性质；第二个是在明确假设下关于延迟对齐的统计命题；其余公式描述读取策略及其答案风险分解。

A.14.1 写入时：状态转移与渐进式对齐

设 $\mathcal{D}$ 是源文档集合。对 $D \in \mathcal{D}$ ，设 $\mathcal{E}(D)$ 是该文档的 Episode 集合。第 i 条观测写为

$$o_i = (D_i, e_i, \tau_i, x_i, \ell_i), \quad e_i \in \mathcal{E}(D_i),$$

其中 τ_i 是处理时间， x_i 是抽取出的内容， ℓ_i 是不可修改的原文位置。设 $O_t = \{o_1, \dots, o_t\}$ ， $M_t = (F_t, O_t, G_t)$ 是写入 t 条观测后的状态。证明中使用的抽象写入算子为

$$\begin{aligned} F_{t+1} &= \text{Align}(F_t, x_{t+1}), \\ O_{t+1} &= O_t \cup \{o_{t+1}\}, \\ G_{t+1} &= \text{Link}(G_t, F_{t+1}, o_{t+1}), \\ M_{t+1} &= (F_{t+1}, O_{t+1}, G_{t+1}). \end{aligned} \tag{5}$$

算子 `Align` 可以建立候选实体族，也可以合并兼容实体族；`Link` 增加或重定向指针。它们都不会改变 ℓ_i 所指向的原文。版本链提供投影 π_t ，满足 $\pi_t(M_{t+1}) = M_t$ ；这正是“后来的状态仍然保留早期状态、可用于审计和修订”的形式化表达。

命题 A.1 (延迟对齐的可修订性). 设 $\mathcal{P}_t$ 是由 F_t 中候选实体族诱导的 O_t 划分。对 $\mathcal{P}_t$ 的任意粗化 $\mathcal{P}'_t$ ，都存在一个不破坏原文的指针映射，使 $\mathcal{P}'_t$ 得以实现，同时不改变 O_t 或任何原文位置。

证明. 把每个旧实体族 f 映射到新实体族 $m(f)$ 。保留每条观测 $o_i = (D_i, e_i, \tau_i, x_i, \ell_i)$ 不变，只把实体族指针替换为 $m(f)$ 。将 G_t 中的边 (f, r, o_i) 替换为 $(m(f), r, o_i)$ 。因此，观测集合和每个 ℓ_i 前后一致，而原来位于不同块中的观测现在可以通过同一个实体族访问。这就实现了 $\mathcal{P}'_t$ ，且没有破坏性重写。拆分也同样安全：只需把指针复制到不同的候选族， O_t 仍不变。若系统只保存确定性摘要 $\sigma = g(O_t)$ ，则对潜在实体身份 Z 有马尔可夫链 $Z \rightarrow O_t \rightarrow \sigma$ 。由数据处理不等式， $I(Z; \sigma) \leq I(Z; O_t)$ ；当 g 丢弃了区分两个身份所需的信息时，不等式可能变为严格不等式。□

命题 A.2 (汇聚证据下的收敛). 假设在给定实体身份的条件下， k 条特征观测相互独立。设两个不同实体 $e \neq e'$ 的特征密度可区分，且其 Chernoff 系数小于 1。记密度为

p_e 与 $p_{e'}$, 其 *Chernoff* 系数和信息定义为

$$\rho_{e,e'} = \inf_{0 \leq s \leq 1} \int p_e(x)^s p_{e'}(x)^{1-s} dx, \quad C_{\text{Ch}}(e, e') = -\log \rho_{e,e'} > 0.$$

对等先验下检验 e 与 e' 的似然比检验, 汇聚 k 条观测后的 *Bayes* 错误满足 (*Chernoff, 1952*)

$$\Pr[\text{error}] \leq \frac{1}{2} \rho_{e,e'}^k = \frac{1}{2} \exp[-k C_{\text{Ch}}(e, e')]. \quad (6)$$

证明. 等先验下, *Bayes* 错误为

$$\Pr[\text{error}] = \frac{1}{2} \int \min \left\{ \prod_{j=1}^k p_e(x_j), \prod_{j=1}^k p_{e'}(x_j) \right\} dx_{1:k}.$$

对 $0 \leq s \leq 1$, 逐点有 $\min\{a, b\} \leq a^s b^{1-s}$. 使用独立性可得

$$\Pr[\text{error}] \leq \frac{1}{2} \prod_{j=1}^k \int p_e(x_j)^s p_{e'}(x_j)^{1-s} dx_j = \frac{1}{2} \left(\int p_e(x)^s p_{e'}(x)^{1-s} dx \right)^k.$$

对 s 取下确界即得到式 (6). 这个界描述的是理想检验; 真实系统距离它有多近, 取决于抽取噪声和窗口相关性. $\square$

因此, 延迟对齐给出一个清楚的定性预测: 更多观测会使正确合并更容易被识别, 而过早的错误合并会把两段历史污染到同一个检索入口。实测的重复实体族数量 (MAB 为 340→124, LongMemEval 为 482→99) 和入库调用下降 (46–65%) 是系统测量值, 不是 C_{Ch} 的估计。

A.14.2 读取时: 层级检索与逐步读取

设 $\mathcal{S}_t$ 是从 M_t 可访问的不可修改源文本片段集合。给定问题 q , 令 $C_0(q) = \emptyset$, 并令

$$a_{k+1} = \rho(q, M_t, C_k(q), u_k) \in (\mathcal{S}_t \setminus C_k(q)) \cup \{\text{stop}\}.$$

若动作是读取某个片段, 则令 $C_{k+1}(q) = C_k(q) \cup \{a_{k+1}\}$; 若动作是 **stop**, 则令 $C_{k+1} = C_k$ 并结束。对 k 做归纳即可证明 $\emptyset = C_0(q) \subseteq C_1(q) \subseteq \dots \subseteq \mathcal{S}_t$: 初始情形显然成立, 归纳步骤只增加 $\mathcal{S}_t$ 中的一个成员, 或什么也不增加。这个公式只记录打开源文本的动作; 索引查询会更新策略状态 u_k , 但不会改变 C_k 。这是读取协议的结构性质, 并不假设每个选中的片段都与问题相关。

设 $A(q)$ 是用于选择候选的紧凑概念/关系记录, E_C 是从 C 打开的精确源文本, Y 是与答案有关的事实。链式法则为

$$\begin{aligned} I(Y; A, E_C \mid Q = q) &= H(Y \mid Q = q) - H(Y \mid A, E_C, Q = q) \\ &= [H(Y \mid Q = q) - H(Y \mid A, Q = q)] \\ &\quad + [H(Y \mid A, Q = q) - H(Y \mid A, E_C, Q = q)] \\ &= I(Y; A \mid Q = q) + I(Y; E_C \mid A, Q = q). \end{aligned} \quad (7)$$

第一步是互信息定义; 第二步是在表达式中加上并减去 $H(Y \mid A, Q = q)$; 最后把两个差值分别识别为两个条件互信息。第一项是定位候选时得到的信息, 第二项是打开原文后得到的额外信息。如果摘要系统把源文档集合 S 替换成 $\tilde{S} = f(S)$, 则在给定 Q 时, 马尔可夫链 $Y \rightarrow S \rightarrow \tilde{S}$ 由数据处理不等式给出 $I(Y; \tilde{S} \mid Q) \leq I(Y; S \mid Q)$ 。Deep-Dream 在地址层缩小搜索范围后仍保留 S ; 它并不声称已经最大化任一互信息项。

表 8: LoCoMo 分类别 J (二值 CORRECT/WRONG 准确率, LLM 评审)。已发表行逐字复现自 Chhikara et al. (2025) (arXiv:2504.19413, 表 1): Mem0 报告 10 次运行的均值 $\pm$ 标准差, 答题与评审均为 GPT-4o-mini (标准差省略, 全部 ≤ 0.75)。Deep-Dream 应用固定在仓库提交 4b61c5d 的二值 J 评分规则——该 2026 修订版评审提示的容差规则异于 2025 年论文的附录 A——以 Kimi-K3 同时作答与评审 (单次运行); $\dagger$ 行用独立的 Qwen3.7-plus 交叉评审评判同一批 K3 答案 (交叉评审一致率 98.51%)。相同的 841/282/96/321 题目群体 (共 1,540 题, Mem0 兼容子集)。注意事项: K3 作答运行被标记 `formal_claim_allowed=false`——1,529 条历史答案行早于运行时代码指纹 (答案未变, sha 76af5772; 逐条 JSONL 携带 `runtime_code_sha256`)。作为诊断性交叉评审结果报告, 而非指纹完备的正式结果。确定性的 F1/BLEU-1 因篇幅省略 (表 12)。加权 J (由已发表分类均值按 841/282/96/321 题量重加权): Mem0 ≈ 62.14 , Mem0^g ≈ 61.36 ; 其论文表 2 另报 Overall $J = 66.88$ (Mem0) 与 68.44 (Mem0^g)。Deep-Dream 聚合 J : 95.19% / 94.22% ($\dagger$)。表体为已发表数据的逐字复现, 保留英文。

Method	J (S/M/O/T)			
LoCoMo	—	/	—	/
ReadAgent	—	/	—	/
MemoryBank	—	/	—	/
MemGPT	—	/	—	/
A-Mem	—	/	—	/
A-Mem*	39.79	/	18.85	/
LangMem	62.23	/	47.92	/
Zep	61.70	/	41.35	/
OpenAI	63.79	/	42.92	/
Mem0	67.13	/	51.15	/
Mem0 ^g	65.71	/	47.19	/
Deep-Dream	97.38	/	93.62	/
Deep-Dream [†]	96.91	/	92.91	/

再设 R_q 表示相关源文本位于最终打开集合 $C_K(q)$ 中, $V_q = \{\hat{Y} = Y\}$ 表示最终答案正确。由全概率公式,

$$\begin{aligned}
 \Pr[V_q | q] &= \Pr[R_q | q] \Pr[V_q | R_q, q] \\
 &\quad + \Pr[\neg R_q | q] \Pr[V_q | \neg R_q, q] \\
 &\geq \Pr[R_q | q] \Pr[V_q | R_q, q].
 \end{aligned} \tag{8}$$

第一项受概念和关系导航影响, 第二项受原文读取和证据判断影响。这个不等式是记账式分解, 不是经验准确率界。

命题 A.3 (地址错误的单侧影响). 假设引用检查器只接受当前读取路径返回的引用 c , 且其位置能解析到不可修改的原文。则 F_t 或 G_t 中的错误可以改变哪些片段进入 $C_K(q)$, 但不能改变已接受引用的文字或位置。

证明. 检查器的接受条件为

$$\text{Accept}(c) = \mathbf{1}\{c \in C_K(q)\} \mathbf{1}\{\text{resolve}(c) = \text{source}(D, \ell)\}.$$

第一项依赖派生地址层, 可能导致相关片段未被找到; 第二项读取不可修改的 (D, ℓ) , 不受 F_t 或 G_t 的编辑影响。因此, 地址错误会造成证据缺失, 却不能把新的文本替换进已接受的源文本引用中。这个命题不保证被接受的片段在语义上一定蕴含答案。 $\square$

以上条件结果解释了设计测量值, 但不把它们包装成未经测量的因果结论: Chernoff 结论是理想化预测, 重复实体族数量是整合程度的代理量, 最终仍需用基准实验检验完整系统。

表 9: 已发表的深度记忆检索 (DMR) 基线, 逐字复现自 Rasmussen et al. (2025) (arXiv:2501.13956)。DMR 包含 500 段多会话对话 (5 个会话、每会话 ≤ 12 条消息), 每段对话一道单跳事实检索题。Deep-Dream 目前未运行 DMR, 因此本表仅作参考。表体保留英文原文。

Method	Answerer	Accuracy
Recursive Summarization	GPT-4-turbo	35.3%
Conversation Summaries	GPT-4-turbo	78.6%
MemGPT	GPT-4-turbo	93.4%
Full-conversation	GPT-4-turbo	94.4%
Zep	GPT-4-turbo	94.8%
Conversation Summaries	GPT-4o-mini	88.0%
Full-conversation	GPT-4o-mini	98.0%
Zep	GPT-4o-mini	98.2%

表 10: LongMemEval 主要结果。已发表行 (GPT-4o-mini / GPT-4o, 全上下文对 Zep) 逐字复现自 Rasmussen et al. (2025) (arXiv:2501.13956)。**Deep-Dream** 行使用 Qwen3.7-plus 作答、Qwen3.7-plus 评审——这是一个不同的协议; 其准确率 (84.6%) 被放在已发表数字旁边, 而非共享榜单。Deep-Dream 的延迟/平均上下文未在已发表协议下测量 (—)。六类别分解见表 11。表体保留英文原文。

Answerer	System	Accuracy	Latency (s)	Avg. context
GPT-4o-mini	Full-context	55.4%	31.30	115k
GPT-4o-mini	Zep	63.8%	3.20	1.6k
GPT-4o	Full-context	60.2%	28.90	115k
GPT-4o	Zep	71.2%	2.58	1.6k
Qwen3.7-plus	Deep-Dream	84.6%	—	—

表 11: LongMemEval 六类别分解 (二值准确率, %)。已发表的全上下文与 Zep 数值逐字复现自 Rasmussen et al. (2025) (arXiv:2501.13956); **Deep-Dream (Q.)** 行是 Qwen3.7-plus 作答 + 交叉评审在相同六个类别上的结果。答题/评审不同, 因此这是粒度匹配的上下文参照, 不是共享榜单。会话偏好 (Sess. pref.) 是所有系统最难的类别。表体保留英文原文。

System	Sess. pref.	Sess. asst.	Temporal	Multi-sess.	Knowledge upd.	Sess. user
Full-ctx (4o-mini)	30.0	81.8	36.5	40.6	76.9	81.4
Zep (4o-mini)	53.3	75.0	54.1	47.4	74.4	92.9
Full-ctx (4o)	20.0	94.6	45.1	44.3	78.2	81.4
Zep (4o)	56.7	80.4	62.4	57.9	83.3	92.9
Deep-Dream (Q.)	53.3	100.0	84.2	74.4	91.0	98.6

表 12: Mem0 LoCoMo 确定性指标, 逐字复现自 Chhikara et al. (2025) (表 1)。四个类别 (单跳/多跳/开放域/时序) 上的 F1 / BLEU-1。Deep-Dream 不计算 token 重叠指标 (其指标为二值 LLM 评审准确率, 表 8), 因此这里没有 Deep-Dream 列; 本表仅为完整性而收录已发表的复现。表体保留英文原文。

Method	F1 (S/M/O/T)	BLEU-1 (S/M/O/T)
LoCoMo	25.02 / 12.04 / 40.36 / 18.41	19.75 / 11.16 / 29.05 / 14.77
ReadAgent	9.15 / 5.31 / 9.67 / 12.60	6.48 / 5.12 / 7.66 / 8.87
MemoryBank	5.00 / 5.56 / 6.61 / 9.68	4.77 / 5.94 / 5.16 / 6.99
MemGPT	26.65 / 9.15 / 41.04 / 25.52	17.72 / 7.44 / 34.34 / 19.44
A-Mem	27.02 / 12.14 / 44.65 / 45.85	20.09 / 12.00 / 37.06 / 36.67
A-Mem*	20.76 / 9.22 / 33.34 / 35.40	14.90 / 8.81 / 27.58 / 31.08
LangMem	35.51 / 26.04 / 40.91 / 30.75	26.86 / 22.32 / 33.63 / 25.84
Zep	35.74 / 19.37 / 49.56 / 42.00	23.30 / 14.82 / 38.92 / 34.53
OpenAI	34.30 / 20.09 / 39.31 / 14.04	23.72 / 15.42 / 31.16 / 11.25
Mem0	38.72 / 28.64 / 47.65 / 48.93	27.13 / 21.58 / 38.72 / 40.51
Mem0 ^g	38.09 / 24.32 / 49.27 / 51.55	26.03 / 18.82 / 40.30 / 40.28