

DEEP-DREAM: 面向智能体长期记忆的时序概念图谱

(中文逐句对应版；图表与数值宏与英文版共用)

Anonymous authors

Paper under double-blind review

ABSTRACT

长期记忆的困难在于：历史不断增长，既要保持易于检索，又不能丢失后续作答所需的精确措辞。Deep-Dream 将这两件事分开：原始文档与精确段落构成事实记录；概念、关系、观测与版本链接负责缩小搜索范围；提问时，智能体只打开并核对回答该问题所需的源文。若早期提及无法确定所指实体，系统保留多个候选，后续观测可以重定向链接而不改写原文。我们在 MemoryAgentBench、LongMemEval、LoCoMo 和 MEME 上评测该设计。在 MemoryAgentBench 上，同一模型、同一评分器下，单次检索结果作答得 0.333，只读记忆工具作答得 0.400，智能体亲自打开的源文作答得 0.710，增益集中在多次提及与更新类问题；同模型全量语料参考界定了选择性阅读尚未覆盖的部分。Mem0 与 Zep 在 LoCoMo 和 LongMemEval 上的已发表分数使用不同的评审模型与评分规则版本，仅作参考参照，不是受控比较。在配对运行中，先记录观测、待更多上下文可用后再合并相容身份的修订写入实现，使每份文档的写入请求减少 46–65%，而抽样质量相近。

1 引言

设想一个约朋友吃饭的场景。几个月前，她说：“我不吃海鲜，最近也在少吃辣。”上周，她又说：“现在可以吃辣了。”再次选餐厅时，如果只记得“她有忌口”，就不知道哪一项发生了变化；如果只记住最新一句，又会遗漏仍然有效的海鲜忌口。一次有效的回忆需要把两次谈话关联到同一个人，区分已经改变和尚未改变的偏好，并保留“最近”“少吃”这样的限定词。

智能体面对不断增长的历史，也需要完成这样的回忆：迅速定位相关事件，同时保留决定未来答案的细节。固定摘要可能在问题尚未出现时就省略这些细节，而每次重读全部历史又会花费大量精力处理无关内容。Deep-Dream 将这一问题分为两个相互配合的过程：先定位相关记忆，再按需读取回答所需的原始证据。




图 1: 检索与证据分离。固定检索一次性决定读什么；Deep-Dream 先沿概念链接定位候选源文本，再由智能体在预算内读取、验证或停止。

Deep-Dream 是一个面向智能体长期记忆的文档优先时序概念图谱。这里“文档优先”指：原始文档和精确源文本跨度是权威证据，图只是导航索引。更具体地说：

- **时序**: 图只有一条状态轴——观测时间。新输入追加观测, 必要时创建新版本; 事件日期保留在观测内容中, 而不是成为第二条状态时间线。更新绝不覆写它所替换的事实, 新旧事实都保持能被找到。
- **概念**: 实体和关系概念是稳定句柄, 不是事实容器。每个概念记录提到它的观测, 并指向精确源文本跨度。概念可以被重读、重审, 但不会被压缩成摘要。
- **图谱**: 这里的图不是知识图谱。知识图谱的节点和边本身承载事实、就是权威; Deep-Dream 的图只是导航层。文档与源文本跨度才是权威; 会话片段、实体与关系概念、观测和版本链接构成一个派生状态, 只回答“下一步应该打开哪个源”。

查询时, 智能体可以搜索、遍历、读取和验证。引用检查只接受由当前读取路径浮现出的源标识符。因此, 对齐错误可能降低覆盖率, 但它无法让一句未被观测的派生句子被算作读取证据。

身份解析是渐进的。首次对齐不确定时, 系统允许一个实体暂时保持为多个候选族; 后续观测和关系邻域可以降低身份不确定性并重定向指针, 而不删除证据。例如, 早期记录只写着“Alex 批准了合同”, 但库中可能同时有实验室的 Alex 和供应商的 Alex, 系统就先保留两个候选族。后来出现“实验室的 Alex 与刘博士共同汇报项目”和“供应商的 Alex 续签了账户”等信息, 组织和关系线索使指针逐步分开, 而无需修改任何原文。若一开始就把两人合并, 查询其中一人时就可能把另一人的合同和项目经历一起取出。这样, 修正在安全性上优于过早合并。

两种写入程序的区别在于实体身份何时最终确定。初始版本 (Base) 在每个窗口到达时立即决定身份; 修订版本 (Align+) 先保存观测和候选匹配, 等周围的证据处理完后合并兼容的实体。两者生成同一种图。

从信息论看 (节 3.4), 固定摘要在问题未知之前就提交了一次有损重构, 而 Deep-Dream 把“读多少原文”的预算推迟给智能体: 对简单查询可以停在紧凑的概念邻域, 不确定性仍高时则花更多预算去读会话片段、关系和源文件。

这些设计提出五个可检验的预测: 逐步读取原文应当有助于合并多次提及或处理后来出现的修正; 观测时间和版本链接应当让旧信息与新信息同时可查; 概念和关系链接应当把分散在不同会话片段中的证据连接起来; 只追加、不删除的存储在删除事实时会失败; 延迟实体对齐应当减少重复实体族和入库成本, 即使不一定提高所有准确率。

四个基准分别覆盖不同能力。MemoryAgentBench (MAB) 让三种回答方式使用相同的问题和记忆库, 区别在于如何找到支持答案的原文: 一次性拿到固定检索结果; 多次调用只读搜索工具; 或者直接打开原始文件并核对引用。LongMemEval 先把一批对话完整写入系统, 再测试旧信息和后来修正能否同时找到。LoCoMo 使用二值 J 评分, 分别包含单跳、多跳、时间变化和开放域问题。MEME 测试被删除的信息、与删除内容相关的信息, 以及原本不存在的信息。匹配运行比较初始和修订后的写入程序。

我们的贡献是:

- **表示**: Deep-Dream 以文档为权威, 用概念、关系、观测和版本构成按观测时间排序、可重建的检索索引。
- **回答与引用检查**: 智能体控制搜索、图扩展、源读取、验证与停止; 检查步骤保证每条引用都能回到实际读过的原文。
- **信息论视角**: 解释为什么导航信息和原文信息应当分开, 并说明查询时如何决定读取多少。
- **分项能力评测**: MAB、LongMemEval、LoCoMo 和 MEME 分别测试不同回答方式、信息更新、跨片段关联和删除能力, 而不是把它们塌缩成一个分数。
- **不同基准上的比较**: 保留各项测试条件, 解释与已发表记忆系统的分数差异, 并报告修订引擎 (Align+) 的成本/整合权衡与负面结果。

三种回答方式同时改变工具、提示词和算力，因此它们比较的是完整系统，不能据此估计某个单独组件的因果作用。MAB 将冻结的 Base 配对样本与原地扩展的 Align+ 样本进行比较；同模型的完整上下文结果只覆盖严格字符预算内的题目，作为实测参照。这里的时序模型是记忆表示和修订原则，并未实现完整的当前值、时点值或撤回语义。

2 相关工作

记忆基准。 LoCoMo 与 LongMemEval 测试长对话、时序更新与多会话推理 (Maharana et al., 2024; Wu et al., 2025)。MEME 增加删除、级联与缺失检查 (Jung et al., 2026)。MemoryAgentBench (MAB) 在一个官方评分框架内评测检索、测试时学习、长程理解与选择性遗忘 (Hu et al., 2025)；我们将其作为主仪器，并让其任务级指标保持可见。

结构化记忆。 MemGPT、A-MEM、Mem0、HippoRAG-2、Cognee、MIRIX 和 Zep/Graphiti 通过摘要、笔记或图改进持久性 (Packer et al., 2023; Xu et al., 2025; Chhikara et al., 2025; Gutiérrez et al., 2025; Markovic et al., 2025; Wang & Chen, 2025; Rasmussen et al., 2025)。Deep-Dream 同样需要紧凑检索，但把权威边界分开：一个派生节点指向一个源文本跨度；它本身不是答案证据。

信息论与联想记忆。 信息瓶颈形式化了在保留与目标变量相关信息前提下的紧凑表示 (Tishby et al., 2000)，率失真理论刻画有损重构的代价 (Shannon, 1959)。联想记忆模型解释从部分线索出发的内容能被找到检索 (Ramsauer et al., 2021)，概率记录链接则区分误链接与漏链接两类错误 (Fellegi & Sunter, 1969)。我们把这些思想用作记忆接口的分析：图层是压缩的检索索引，精确文本是保留的证据，延迟的实体合并用可容忍的漏链接代价，换取对灾难性误链接污染的规避。

检索、长上下文与来源记录。 检索增强生成负责选择证据 (Lewis et al., 2020)。Agentic 检索则把检索决策暴露给模型：A-RAG 将关键词、语义与分块阅读工具交给一个在开放域多跳语料上的推理模型，并报告在可比或更少检索 token 下随测试时算力扩展的准确率 (Du et al., 2026)；其人工失败分析将实体混淆识别为主导残差错误，而对话与长篇记忆不在其测试设置内。Deep-Dream 共享渐进披露原则，但将其应用于长期记忆而非静态语料：概念与版本链接、只增观测和源跨度权威让后续读取可验证，而不仅是更便宜；实体混淆正是我们的对齐层与延迟合并设计要降低的失败类别。当相关跨度远离注意力窗口两端时，长上下文模型可能丢失信息 (Liu et al., 2024)。归因工作通常在生成之后检查引用 (Gao et al., 2023)；我们的引用检查只确认被引用的原文确实被打开。它并不证明蕴含，我们显式报告这一局限。

3 DEEP-DREAM

3.1 记忆模型

设 D 为一份源文档， e_i 为从其某个跨度中抽取的一条会话片段。Deep-Dream 把 D 、版本、会话片段和精确的源偏移保存为权威数据。实体族 f 是一个稳定的搜索句柄；每条观测 $o_{f,i}$ 记录某个源断言了什么、何时断言、以及可以在哪里重读。关系使用同样的“族/断言”二分。处理中的文档在发布之前保持隐藏，活跃观测与历史观测相互分离。派生层的更新因此只添加或合并指针，而不改写源文本。

3.2 入库与对齐：两代引擎

Base 与 Align+ 的差别在于何时提交实体身份。 它们是同一个构建引擎的两代，在同样的文档上建同一种图。Base 立即决定：每个窗口一到就对齐并整合，没有最终调和。因此一次早期漏匹配会留下重复族，一次早期误合并会把另一个实体的观测污染进同一个检索位置。Align+ 把证据捕获与身份提交分开：窗口并发入库、候选匹配保持开放，兼容的族只在同一任务组中的所有窗口处理完后才合并——推迟是为了让关系构建不会读到一个移动中的目标。一句话：Base 是“现在就决定”；Align+ 是“先记录，拿到更多上下文再决定”。

具体地, Remember 流水线先按标题分块、抽取并校验实体和关系、保守地合并候选,并在多个窗口处理完后做一次统一检查。早期过切分是可恢复的,因为观测保留其源链接。合并后的 Align+ 修订具有更少的同名重复实体族 (MAB 上 340→124; LME 上 482→99) 和每文档 46–65% 更少的观测入库调用; 这些测量并未把收敛与伴随变更分离开来。

3.3 三种回答方式与引用检查

三种回答方式使用相同的问题流、冻结库、答题模型、评分器和任务组资格; 区别只在于如何取得支持答案的原文:

1. **直接检索 (只读一次)**。系统返回一组词法、语义和图检索结果; 独立的答题模型只看这组结果, 不能继续索取信息。
2. **工具辅助读取**。智能体可以多次调用只读搜索和记录工具; 停止后, 把整理出的记录交给独立的答题模型。这种方式不会打开原始文件。
3. **直接读取原文的智能体**。系统先选出相关文档组, 智能体用普通工具打开原始文件, 并且只引用自己实际读过的文本。

由于工具、提示词和算力会一起改变, 这里比较的是完整系统而非单个组件。另一个通道重放实验只改变派生搜索通道。

引用检查不依赖 LLM。只有当前问题的工具调用返回了某个源标识符、该标识符属于允许读取的文档组、并且系统还保留着对应原文指针, 引用才会被接受。这能确认引用来自智能体实际打开过的文本, 但不保证文本一定相关。运行时为每条记录保存工具观测、源文本 ID、延迟、退出状态和代码/运行时哈希。

候选记录通过倒数排名融合合并词法、语义、概念、关系与图邻域通道, 并解析到会话片段与跨度; 在原文读取方式中图层只负责选择文档组, 因此一个定位错误造成的是覆盖缺失, 而不是捏造引用。

3.4 信息论视角下的渐进披露

写入时: 信息只增不减。设 $X_{1:t}$ 为从前 t 个源跨度抽取的观测, Z 为其潜在实体指派, $M_t = (F_t, O_t, G_t)$ 为持久状态: 概念族、只增观测库、关系图。入库增加一条观测并可能重定向某个族, 但从删除观测:

$$\begin{aligned} O_{t+1} &= O_t \cup \{(X_{t+1}, \text{span}_{t+1})\}, \\ I(Z; O_{1:t+1}) &= I(Z; O_{1:t}) + I(Z; X_{t+1} | O_{1:t}) \geq I(Z; O_{1:t}). \end{aligned} \quad (1)$$

这一恒等式是记账事实, 不是定理: 因为没有东西被丢弃, 首次对齐只是临时划分, 而早期误合并才是危险的错误——它把两个实体的证据污染进同一个检索位置。在理想化 i.i.d. 特征模型下, 一次真实合并未被检测到的概率随汇聚证据指数下降 (附录 A.14); 关系端点共现提供额外的判别特征, 并在之后成为一条检索边。

读取时: 先找到位置, 再读原文。对查询 q , 设 A 为概念族与关系路径返回的紧凑检索记录, E_C 为从所选候选集 C 打开的精确跨度, Y 为答案相关事实:

$$I(Y; A, E_C | Q = q) = I(Y; A | Q = q) + I(Y; E_C | A, Q = q). \quad (2)$$

第一项是导航信息; 第二项是打开原文后才能得到的额外事实。纯摘要记忆把源 S 替换为 $f(S)$, 只可能损失信息 (数据处理不等式); Deep-Dream 保持 S 能被找到, 把读取速率推迟给智能体。这也解释了为什么静态召回消融近乎为零并不与在线增益矛盾: 图不必包含答案, 它只需提高下一次读取的条件信息。

智能体决定读取多少原文。读取在策略 $a_{k+1} = \rho(q, M_t, C_{\leq k}, u_k)$ (u_k 为当前不确定性) 下沿 $C_0(q) \subseteq C_1(q) \subseteq \dots \subseteq S$ 推进。每个被引用的跨度都属于 S , 因此重构失真按构造为零, 唯一失败模式是定位失败——相关跨度从未进入 C_k 。部署的智能体读取到不

确定性足够低或引用检查无法通过为止。若 R_q 表示相关跨度被找到、 V_q 表示随后验证成功，则

$$\Pr[\hat{Y} = Y | q] \geq \Pr[R_q | q] \Pr[V_q | R_q, q], \quad (3)$$

因此图层主要帮助找到相关原文，源文本阅读负责核对事实。这预测了观测到的形态：增益集中在同时需要两个因子的多次提及与事实整合任务上，而仅图离线重放几乎不动。

4 实验

实验覆盖检索、时序访问、多跳关联、写入效率和删除能力。

4.1 测试设置与任务组

主基准。MAB 贡献了一个来自 10 个任务组、59 份文档的 767 题配对样本，并在 Align+ 引擎上扩展为来自 14 个任务组的 1,074 题（完整基准为 29 个任务、3,671 题）。配对样本覆盖八个任务；扩展补上 AR 的 MH-QA (RULER-421K) 与 TTL 的推荐任务（完整 Redial 语料），二者都超出完整上下文对照组的字符预算。所有分数使用官方评分器。¹Kimi-K3 为所有方式和两个引擎代际作答：Base 是冻结在配对样本上的初始引擎；Align+ 是使用扩展样本的修订引擎。

其他基准。LongMemEval 先把整批对话写入系统，再用三种回答方式处理配对样本 $n = 25/25/27$ （直接读取原文的方式多两题）；样本很小，所以结果主要用于观察趋势。独立的 500 题 LME-S 运行由 Qwen3.7-plus 交叉评审，结果为 84.60%。LoCoMo-1540 使用 Mem0 的二值 J 评分：每题答对记 1、答错记 0，再取平均。MEME 测试删除与缺失。

MAB 的分数是百分比：100 表示该行所有题目都答对，0 表示全部答错，因此分数越高越好。AR 是“准确检索” (Accurate Retrieval)，TTL 是“测试时学习” (Test-Time Learning)，LRU 是“长程理解” (Long-Range Understanding)，SF 是“选择性遗忘” (Selective Forgetting)。MCC 指“多类别分类”，Recom 是用 Recall@5 评分的电影推荐，SH/MH 表示单跳/多跳，FC-SH/FC-MH 表示事实整合的单跳/多跳题。Recall、 J 、精确匹配和 Overall 都是越高越好；调用次数、token 数和字节数是成本，越低越好。

4.2 RQ1：逐步读取原文能否改进答案？

表 1 报告六个冻结的 MAB 运行。读取原文的方式得分最高，在 MCC 和 FC-MH 上尤其明显。

当答案需要多次提及或更新时，多读源文本帮助最大。在扩展后的问题上，Align+ 的直接检索、工具辅助读取、原文读取智能体分别得分 0.333/0.400/0.710；Base 在冻结配对样本上得分 0.303/0.376/0.669。配对 bootstrap 区间为 +0.067 [+0.023, +0.117] 和 +0.310 [+0.253, +0.369]。这些路径同时改变了工具、提示词、答题模型安排和算力，因此该比较不是单因素因果检验。读取原文把 MCC 从 2 提升到 46、FC-MH 从 3 提升到 70，两个扩展任务则把各路径拉开：原文读取智能体在 421K RULER 任务组上达到 77.0、在完整 Redial 语料上达到 59.8，而同模型的完整上下文对照组无法覆盖这些文档组。配对样本中 $n=1$ 的 ∞ Bench-Sum 单例行从 21.2 变为 0.0；将其剔除后，Align+ 在该配对样本上为 75.5、Base 为 74.7。因此两个引擎呈现的是成本/质量权衡，而不是一个排名。

同模型的完整上下文对照组是一个实测参考，而不是单独的竞争系统：它每一轮都把每个任务组的全文重新送入提示，并且只覆盖其严格字符预算内 1,074 题中的 614 题 (57%)。在这些题目上，原文读取智能体得分 0.708，完整上下文对照组的 0.787（配对差距 -7.9[-11.9,-3.9] 个百分点）——这是把记忆经由导航层而非窗口传递的实测代价。该差距集中在 TTL (75.0 对 46.0)，完整上下文对照组在那里直接构造多文档状态；智能体在 AR (95.0 对 96.8)、LRU (62.3 对 65.2) 和 SF (80.0 对 78.0) 上与之持平或

¹ 本文使用的评分器版本为 commit 455306d。




图 2: MemoryAgentBench 的回答方式与任务结果 (官方评分器, Kimi-K3 作答)。(a) Overall 分数: Base 取冻结配对样本 ($n=767$), Align+ 取扩展样本 ($n=1074$), 带边缘 95% bootstrap 区间; (b) 扩展样本上的 Align+ 域分数; (c) 所选任务分数; (d) 扩展样本全部 209 个残余零分条目。两个样本分别标注。

反超, 选择性阅读避免了窗口稀释。完整上下文对照组无法覆盖 460 道超窗题目, 原文读取是这些题目的唯一作答方式。

一条实测轨迹 (图 6, 附录) 完整展示了该循环: 一次词法未命中触发概念扩展, 源文本跨度浮现出三条销售记录, 答案返回 495。

4.3 RQ2: 时序化、版本化状态是否有助于更新与会话?

LongMemEval 检验较早的观测与较晚的更正是否都保持可用。配对轨道使用相同的问题 ID 和答题模型, 但 $n = 25/25/27$ 是方向性的。独立的 500 题 LME-S 分数为 84.60% (Qwen3.7-plus 交叉评审); 它是一套单独的测试流程, 因此不与其他结果合并排名。

最大的上下文差出现在时序与知识更新问题上, 那里新旧源跨度必须保持能被找到。会话偏好问题仍是边界, 因为它们需要潜在用户状态建模。这个结果说明了时序访问能力, 但不代表所有时序推理任务。

4.4 RQ3: 概念与关系路径能否支撑多跳整合?

我们以固定在仓库提交 4b61c5d 的 Mem0 基准库二值 CORRECT/WRONG 评分规则为 LoCoMo-1540 打分——该 2026 修订版的日期、时长与列表容差规则异于 2025 年论文的附录 A——Kimi-K3 同时作答与评审; 同一批答案经独立的 Qwen3.7-plus 交叉评审为 94.22% (一致率 98.51%)。Deep-Dream 取得 95.19% 的加权 J (评审判为正确的百分比), 这是一次带已披露遗留指纹注意事项的诊断性运行, 而非指纹完备的正式结果。作为背景: 将 Mem0 已发表的分类均值按同样的 841/282/96/321 题量重加权得 ≈ 62.14 (其论文表 2 报告 Overall $J = 66.88$), Zep 的分类均值同样重加权得 ≈ 56.32 ; 这些行使用不同的答题模型、评审与协议, 仅作背景参照, 不构成受控比较。

该形态与设计一致: 多跳问题需要概念聚合、关系遍历和回到精确源跨度; 时序问题还需要更新顺序与旧版本。开放域问题通常只需要一条会话片段。完整测试细节与遗留指纹说明见附录。

任务 / 域	直接检索		工具辅助读取		原文读取		Align+
	Base	Align+	Base	Align+	Base	Align+	Align+ 增益
AR: 准确检索 (Accurate Retrieval)							
SH-QA	54.0	48.0	84.0	72.0	94.0	<u>92.0</u>	44.0
MH-QA [†]	–	22.0	–	<u>42.0</u>	–	77.0	–
LongMemEval-S*	26.7	41.7	43.3	51.7	90.0	<u>88.3</u>	46.6
EventQA	<u>90.3</u>	89.7	<u>90.7</u>	88.3	98.0	98.0	8.3
TTL: 时序与测试时学习 (Temporal and Test-time Learning)							
MCC, icl_clinic150	4.0	2.0	3.0	2.0	<u>43.0</u>	46.0	44.0
Recom [†]	–	<u>3.2</u>	–	<u>3.2</u>	–	59.8	–
LRU: 长程理解 (Long-range Understanding)							
∞ Bench-Sum [†]	0.0	0.0	<u>28.4</u>	29.8	21.2	0.0	0.0
DetectiveQA	50.0	<u>66.7</u>	50.0	83.3	83.3	83.3	16.6
SF: 选择性遗忘 (Selective Forgetting)							
FC-SH	<u>68.0</u>	66.0	67.0	63.0	90.0	90.0	24.0
FC-MH	2.0	3.0	4.0	4.0	<u>67.0</u>	70.0	67.0
Overall ($n = 767$)	30.3	32.4	37.6	40.7	66.9	<u>65.1</u>	32.7
Overall ($n=1074$, 扩展)	–	33.3	–	40.0	–	71.0	–

表 1: MemoryAgentBench; 分数为官方分量分数 $\times 100$ 。任务行与 Overall ($n=767$) 行使用两个引擎共享的配对样本。[†] 标记 Align+ 引擎原地扩展到 $n=1074$ 时新增的两个任务组 (RULER-421K 多跳问答与完整 Redial 推荐语料); Base 运行冻结在配对样本上, 且两个任务组都超出完整上下文行的严格字符预算 (附录 A.3), 因此没有同模型覆盖。Overall ($n=1074$) 行即该扩展样本; 两个样本的分数绝不相减。加粗/下划线为各任务与样本内的最佳/次佳, * 标记抽样的 LongMemEval-S, [†] 标记配对样本的单例 ∞ Bench-Sum 行 (第二个任务组仅进入扩展样本, 因此 LRU 仍是方向性的: 配对 $n=7$ 、扩展 14)。

4.5 RQ4: 延迟确定身份能否降低写入成本?

Base 逐窗口提交实体身份; Align+ 把合并推迟到同一任务组中的所有窗口处理完 (机制见节 3)。在配对运行中, 调用数从每 MAB 文档 609 降到 329 (-46%)、每 LME 文档从 63.8 降到 22.0 (-65.5%)。同名重复族从 340 降到 124 (MAB)、从 482 降到 99 (LME); MCC 与 FC-MH 各上升 0.03, 区间为 $+0.030 [-0.070, +0.130]$ 和 $+0.030 [-0.070, +0.130]$ 。并发、收敛、重试、超时和吞吐修复是一起改的而不是逐一改的, 因此该结果反映成本与可修订性的权衡, 不能视为组件消融。

4.6 RQ5: 只保留历史的设计在哪里失败?

MEME 标出当前边界: 100 个会话片段上删除准确率为 0%, 而级联与缺失的真实准确率为 46.34 和 59.23。该存储保留历史观测和链接, 但没有查询时抑制或删除传播。TTL 也低于最强的全上下文 MAB 行。时序修订与删除是两种不同的能力。

4.7 与其他系统的比较

表 2 汇总 MAB、LoCoMo 和 LongMemEval-S 的结果。

Deep-Dream 用图来定位, 用源文本作为事实依据。最干净的等长、免评审 MAB 比较是 SH-QA (92 对 87) 和 DetectiveQA (83.3 对 77.5)。EventQA 和 FactConsolidation 使用不同的上下文长度 (我们的 FC 文档组长度为 6K; 已发表行平均 262K), Overall 59–61 对 49.6 使用了不同的模型与子集。MAB 内部的同模型对照是受控比较; 跨协议的各行并排放置仅作背景, 不主张跨协议差值。

4.8 机制诊断: 离线检索与在线读取

这个诊断问的是: 图谱是否会在智能体打开原文之前提高排序质量。我们在同一批 210 道问题上使用四种索引: 原始文档加 episode 关键词检索 (BM25); 加入语义链接; 加入图邻居; 加入关系链接。Recall-any@10 表示前十个结果中是否至少有一个相关项,

(a) MemoryAgentBench (官方评分器)						
系统 / 答题模型	AR	TTL	LRU	SF	Overall	
Full-context / GPT-4o	58.1	50.0	54.9	32.5	48.8	
Full-context / GPT-4o-mini	49.2	48.6	46.2	25.0	42.2	
Full-context / GPT-4.1-mini	71.8	46.2	49.1	20.5	46.9	
Full-context / Gemini-2.0-Flash	65.1	46.4	41.6	16.5	42.4	
Full-context / Claude-3.7-Sonnet	59.7	53.9	62.2	22.5	49.6	
BM25 RAG / GPT-4o-mini	60.5	44.5	35.6	25.5	41.5	
HippoRAG-2 / GPT-4o-mini	65.1	35.8	36.2	29.5	41.6	
MIRIX / GPT-4.1-mini	63.0	35.7	40.5	11.5	37.7	
MemGPT / GPT-4o-mini	34.3	40.8	22.4	15.5	28.3	
Zep / GPT-4o-mini	37.5	37.5	16.2	5.0	24.0	
Mem0 / GPT-4o-mini	32.6	21.2	20.7	10.0	21.1	
Deep-Dream / 完整上下文 (Kimi-K3, $n=614$)	96.8	75.0	65.2	78.0	78.7	
Deep-Dream / 直接检索 (Kimi-K3)	50.3	2.6	45.9	34.5	33.3	
Deep-Dream / 工具辅助读取 (Kimi-K3)	63.5	2.6	60.4	33.5	40.0	
Deep-Dream / 原文读取 (Kimi-K3)	88.8	52.9	62.3	80.0	71.0	

(b) LoCoMo 二值 J (%; Mem0 协议)						
系统 / 评审	单跳	多跳	开放域	时序	加权	
Mem0 / GPT-4o-mini	67.13	51.15	72.93	55.51	≈ 62.14	
Mem0 ^g / GPT-4o-mini	65.71	47.19	75.71	58.13	≈ 61.36	
Zep / GPT-4o-mini	61.70	41.35	76.60	49.31	≈ 56.32	
LangMem / GPT-4o-mini	62.23	47.92	71.12	23.43	≈ 52.08	
OpenAI / GPT-4o-mini	63.79	42.92	62.29	21.71	≈ 51.10	
A-Mem* / GPT-4o-mini	39.79	18.85	54.05	49.91	≈ 38.95	
Deep-Dream / Kimi-K3	97.38	93.62	80.21	95.33	95.19	
Deep-Dream / Qwen3.7-plus 交叉评审	96.91	92.91	77.08	93.46	94.22	

(c) LongMemEval-S (%)							
系统 / 答题模型	Overall	会话偏好	会话助手	时序	多会话	知识更新	会话用户
Full-context / GPT-4o-mini	55.4	30.0	81.8	36.5	40.6	76.9	81.4
Zep / GPT-4o-mini	63.8	53.3	75.0	54.1	47.4	74.4	92.9
Full-context / GPT-4o	60.2	20.0	94.6	45.1	44.3	78.2	81.4
Zep / GPT-4o	71.2	56.7	80.4	62.4	57.9	83.3	92.9
Deep-Dream / Qwen3.7-plus	84.6	53.3	100.0	84.2	74.4	91.0	98.6

表 2: MemoryAgentBench、LoCoMo 与 LongMemEval-S 的与已发表系统的比较结果; 已发表行来自 Hu 等 (Hu et al., 2025)、Chhikara 等 (Chhikara et al., 2025) 与 Rasmussen 等 (Rasmussen et al., 2025)。每个分块都列出答题模型、评审、子集与测试流程。(b) 块的加权列由已发表分类均值按 841/282/96/321 题量重加权重算; 跨块各行使用不同协议, 仅作参考, 不构成受控比较。我们的 MAB 行使用 Align+ 扩展样本 ($n=1074$, 14 个任务组; 附录 A.3); 同模型完整上下文行是 614/1,074 覆盖上的参照行而非竞争系统, 其对原文读取的领先 (-7.9 个百分点, 95% CI $[-11.9, -3.9]$) 在节 4.2 中分析。LRU 格是方向性的 ($n=14$; ∞ Bench-Sum $n=2$)。

Recall-all@10 表示相关项是否全部出现; MRR@10 和 nDCG@10 都会奖励相关项排在更前面。四种索引的 Recall-any@10 依次为 72.38、72.38、71.43 和 72.38%; 每个配对差异都落在由同一重放计算出的 ± 2.4 个百分点 95% bootstrap 等价界内, 其他指标也没有稳定变化。

因此, 离线重放没有证据表明仅加入图链接就能提高召回率。在线运行时, 图仍然负责在读取原文前选择文档组、版本和关系链接; 引用检查只接受智能体确实从工具调用中读到的源标识符。图 7 给出三种回答路径的成本: 原文读取使用更多调用和 token, 但得到最高答案分数。

4.9 系统仍然失败的地方

原文读取方式在 MAB 中仍有 29.0% 的题目答错, 错误集中在时序/测试时学习和事实整合。直接检索与工具辅助读取在小型配对 LongMemEval 轨道上打平, LRU 只有 14 道题, 同一批 210 道问题也没有显示离线召回变化。MEME 的 0% 删除准确率, 以及

一个样本就能改变汇总分数的现象表明，保留原文并不等于已经支持删除，也不能保证每个任务都有稳定估计。

5 分析与局限

这里的科学问题是：历史不断增长、每次提问又只能读取其中一部分时，记忆系统怎样同时做到“找得到”和“信得过”。只保存摘要会在写入时丢掉原句和限定条件；只保存图节点容易把派生链接误当成事实；每次读取全部文档又会反复支付成本并超过上下文窗口。Deep-Dream 将三件事分开：概念和关系负责定位候选材料，观测和原文段落负责确认事实，智能体决定还要读取多少证据。

因此，图谱的作用不应只看离线排序是否提高。图谱不必在节点中保存完整答案，也不必单独提高前十名召回率；它首先要用较小的记录找到文档组、版本和相关会话，再把读取引向原文。通道重放结果支持这种解释：图是地址层，不是第二个事实库。MAB 中需要合并多次提及或核对更新的问题得到提升，说明导航和原文读取要配合使用；LoCoMo 则说明关系路径能够连接多个会话，但事实权威仍在被链接的原文。

渐进式对齐回答的是另一个问题：第一次提及无法确定身份，系统应该怎么办。保留两个候选族可以暂时保存这种不确定性；后续观测能够重定向指针、合并兼容族，而不改写成最初拆分的原文。过早错误合并会把两段历史污染到同一个地址，之后更难恢复。因此 Align+ 是一种允许修订的写入策略，而不只是更快的抽取器。它减少了调用次数和重复实体族，说明推迟身份决定可以减少重复工作；但并发和其他运行时改动是一起加入的，不能据此判断某个组件的单独因果作用。

时序原则规定了长期记忆的状态轴：处理或观测时间负责排列版本，事件日期仍保留在观测原文中。新信息增加版本或指针，同时保留旧段落，所以早先说法和后来的更正仍能一起找到。这保留了理解变化所需的历史，但没有规定用户要求删除后哪些观测应被抑制。MEME 暴露了这个缺口：时序修订和删除是两种不同的能力。

读取时，信息论模型预测的是自适应读取预算，而不是一个固定摘要长度（节 3.4）。式 (2) 中的地址信息应当便宜，用来导航；真正决定答案的措辞来自打开的原文。局部问题可以较早停止，多跳、更新或冲突问题则应继续扩展关系并读取更多段落。式 (3) 区分了两种失败：没有找到段落，或找到了却核对错误。现有结果支持原文读取和可修订写入的作用，但没有直接测量熵下降。

这些结论有明确边界。MAB 的三种方式是完整系统比较，不是单组件因果实验；Long-MemEval 和 LRU 子集较小；公开横向结果使用不同模型、评审和子集。公式说明设计中的信息流，不是已经测得的增益，也不是最优性证明。引用检查只能确认段落确实由工具返回，不能证明它足以支持答案。后续应测量实体不确定性、错误合并污染、固定读取预算下的准确率，以及删除、截至时间、冲突处理和置信度校准。

6 结论

长期记忆必须在增长的历史中找到相关过去，保留使事实可信的原句和限定条件，并在新观测出现后修正身份和判断。Deep-Dream 用以文档为事实源的时序概念图谱回答这一问题：概念、关系和版本构成地址层，只增观测和原文段落构成事实层，智能体控制证据展开。

这区别于写入时就丢失细节的摘要记忆、容易把派生链接当成事实的纯图记忆，以及对每个问题都支付完整输入成本的固定上下文。结果表明，差异在需要合并多次提及、核对更新或跨会话寻找材料时最有价值；推迟实体合并也减少了重复写入。同时，图链接本身不保证离线召回提升，删除历史的抑制机制尚未实现，部分时序任务仍然困难。

本文更一般的贡献是提出四个评价长期记忆的设计问题：什么被压缩用于寻址，什么必须作为事实保留，身份如何随证据修正，以及谁决定读取预算。这些问题可以指导未来的删除、冲突处理和证据置信度基准。

AI 协助

我们使用了基于 LLM 的协助（包括 OpenAI Codex）来起草、重构和编辑手稿；准备中文阅读版；检索相关文献与书目信息；以及协助分析与绘图代码。生成式图像工具用于创建和修改解释性框架图。

AI 协助还参与了架构的信息论解释、数学主张及其论证的表述，以及实验方法与结果的讨论。这包括渐进式实体对齐的处理、检索——证据分离，以及依赖查询的读取预算。这些论证以论文中声明的假设为条件；AI 协助不构成独立的证明验证或实证校验。

本论文准备流程中未创建任何合成评测数据集。报告的基准分数取自有记录的实验运行，而不是生成的性能估计。作者对最终文本、引用、数学主张、代码、图表和实证结论负责，包括对 AI 协助材料的核验。

REFERENCES

- Herman Chernoff. A measure of asymptotic efficiency for tests of a hypothesis based on the sum of observations. *The Annals of Mathematical Statistics*, 23(4):493–507, 1952. doi: 10.1214/aoms/1177729330. URL <https://doi.org/10.1214/aoms/1177729330>.
- Prateek Chhikara, Dev Khant, Saket Aryan, Taranjeet Singh, and Deshraj Yadav. Mem0: Building production-ready ai agents with scalable long-term memory. *arXiv preprint arXiv:2504.19413*, 2025. URL <https://arxiv.org/abs/2504.19413>.
- Mingxuan Du, Benfeng Xu, Chiwei Zhu, Shaohan Wang, Pengyu Wang, Xiaorui Wang, and Zhendong Mao. A-RAG: Scaling agentic retrieval-augmented generation via hierarchical retrieval interfaces. *arXiv preprint arXiv:2602.03442*, 2026. URL <https://arxiv.org/abs/2602.03442>.
- Ivan P. Fellegi and Alan B. Sunter. A theory for record linkage. *Journal of the American Statistical Association*, 64(328):1183–1210, 1969. doi: 10.1080/01621459.1969.10501049. URL <https://doi.org/10.1080/01621459.1969.10501049>.
- Tianyu Gao, Howard Yen, Jiatong Yu, and Danqi Chen. Enabling large language models to generate text with citations. In *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 6465–6488, Singapore, 2023. Association for Computational Linguistics. doi: 10.18653/v1/2023.emnlp-main.398. URL <https://aclanthology.org/2023.emnlp-main.398/>.
- Bernal Jiménez Gutiérrez, Yiheng Shu, Weijian Qi, Sizhe Zhou, and Yu Su. From rag to memory: Non-parametric continual learning for large language models. In *Proceedings of the 42nd International Conference on Machine Learning*, volume 267 of *Proceedings of Machine Learning Research*, pp. 21497–21515. PMLR, 2025. URL <https://proceedings.mlr.press/v267/gutierrez25a.html>.
- Yuanzhe Hu, Yu Wang, and Julian McAuley. Evaluating memory in llm agents via incremental multi-turn interactions. *arXiv preprint arXiv:2507.05257*, 2025. URL <https://arxiv.org/abs/2507.05257>.
- Seokwon Jung, Alexander Rubinstein, Arnas Uselis, Sangdoo Yun, and Seong Joon Oh. Meme: Multi-entity & evolving memory evaluation. *arXiv preprint arXiv:2605.12477*, 2026. URL <https://arxiv.org/abs/2605.12477>.
- Patrick S. H. Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wen-tau Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive NLP tasks. In *Advances in Neural Information Processing Systems*, volume 33, pp. 9459–9474, 2020. URL <https://arxiv.org/abs/2005.11401>.

- Yifei Li, Weidong Guo, Lingling Zhang, Rongman Xu, Muye Huang, Hui Liu, Lijiao Xu, Yu Xu, and Jun Liu. Locomo-plus: Beyond-factual cognitive memory evaluation framework for LLM agents. In *Proceedings of the 64th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 25085–25100, San Diego, California, United States, July 2026. Association for Computational Linguistics. doi: 10.18653/v1/2026.acl-long.1150. URL <https://aclanthology.org/2026.acl-long.1150/>.
- Nelson F. Liu, Kevin Lin, John Hewitt, Ashwin Parandekar, Danqi Chen, and Percy Liang. Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12:157–173, 2024. doi: 10.1162/tacl_a_00638. URL <https://arxiv.org/abs/2307.03172>.
- Adyasha Maharana, Dong-Ho Lee, Sergey Tulyakov, Mohit Bansal, Francesco Barbieri, and Yuwei Fang. Evaluating very long-term conversational memory of LLM agents. In *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 13851–13870, Bangkok, Thailand, 2024. Association for Computational Linguistics. doi: 10.18653/v1/2024.acl-long.747. URL <https://aclanthology.org/2024.acl-long.747/>.
- Vasilije Markovic, Lazar Obradovic, Laszlo Hajdu, and Jovan Pavlovic. Optimizing the interface between knowledge graphs and llms for complex reasoning. *arXiv preprint arXiv:2505.24478*, 2025. URL <https://arxiv.org/abs/2505.24478>.
- Charles Packer, Sarah Wooders, Kevin Lin, Vivian Fang, Shishir G. Patil, Ion Stoica, and Joseph E. Gonzalez. Memgpt: Towards llms as operating systems. *arXiv preprint arXiv:2310.08560*, 2023. URL <https://arxiv.org/abs/2310.08560>.
- Hubert Ramsauer, Bernhard Schöfl, Johannes Lehner, Philipp Seidl, Michael Widrich, Lukas Gruber, Markus Holzleitner, Thomas Adler, David Kreil, Michael K. Kopp, Günter Klambauer, Johannes Brandstetter, and Sepp Hochreiter. Hopfield networks is all you need. In *International Conference on Learning Representations*, 2021. URL <https://arxiv.org/abs/2008.02217>.
- Preston Rasmussen, Pavlo Paliychuk, Travis Beauvais, Jack Ryan, and Daniel Chalef. Zep: A temporal knowledge graph architecture for agent memory. *arXiv preprint arXiv:2501.13956*, 2025. URL <https://arxiv.org/abs/2501.13956>.
- Claude E. Shannon. Coding theorems for a discrete source with a fidelity criterion. In *IRE National Convention Record*, volume 7, pp. 142–163, 1959. URL <https://ieeexplore.ieee.org/document/5311476>.
- Mohit Shridhar, Xingdi Yuan, Marc-Alexandre Côté, Yonatan Bisk, Adam Trischler, and Matthew Hausknecht. Alfworld: Aligning text and embodied environments for interactive learning. In *International Conference on Learning Representations*, 2021. URL <https://openreview.net/forum?id=0IOX0YcCdTn>. ICLR 2021.
- Naftali Tishby, Fernando C. Pereira, and William Bialek. The information bottleneck method. *arXiv preprint physics/0004057*, 2000. URL <https://arxiv.org/abs/physics/0004057>.
- Yu Wang and Xi Chen. Mirix: Multi-agent memory system for llm-based agents. *arXiv preprint arXiv:2507.07957*, 2025. URL <https://arxiv.org/abs/2507.07957>.
- Di Wu, Hongwei Wang, Wenhao Yu, Yuwei Zhang, Kai-Wei Chang, and Dong Yu. Longmemeval: Benchmarking chat assistants on long-term interactive memory. In *International Conference on Learning Representations*, 2025. URL https://proceedings.iclr.cc/paper_files/paper/2025/hash/d813d324dbf0598bbdc9c8e79740ed01-Abstract-Conference.html. ICLR 2025.

Wujiang Xu, Zujie Liang, Kai Mei, Hang Gao, Juntao Tan, and Yongfeng Zhang. A-mem: Agentic memory for llm agents. In *Advances in Neural Information Processing Systems*, volume 38, 2025. doi: 10.52202/085713-0593. URL https://proceedings.neurips.cc/paper_files/paper/2025/hash/19909c36f51abc4856b4560aff3d36d6-Abstract-Conference.html.

Terry Yue Zhuo, Minh Chien Vu, Jenny Chim, Han Hu, Wenhao Yu, Ratnadira Widyasari, et al. Bigcodebench: Benchmarking code generation with diverse function calls and complex instructions. In *International Conference on Learning Representations*, 2025. URL https://proceedings.iclr.cc/paper_files/paper/2025/hash/a6a90bcc2aa470c3871b2d39a67d26e8-Abstract-Conference.html. ICLR 2025.




图 3: Deep-Dream 的文档优先时序概念图谱。多份文档保留各自的会话片段, 并通过共享的概念族与关系边连接。选中一个族会暴露其按观测时间排列的版本链, 以及每次修订的精确源跨度; 不确定的匹配可以先保持分离, 等到后续内容与关系上下文到达时再收敛。




图 4: 同模型完整上下文参照覆盖的 $n=614$ 题上的问题对齐 (Kimi-K3 作答; 官方宏平均评分器)。(a) 带边缘 95% bootstrap 区间的 Overall 分数; 原文读取方式低于参照 7.9 个百分点 [95% CI -11.9, -3.9]。(b) 域画像: 参照的领先集中在 TTL, 而原文读取方式在 AR、LRU、SF 上与参照持平或反超。

A 可复现性与审计细节

A.1 工件账本

机器可读账本由发布的账本脚本与重算脚本生成。它记录论文所引每一次运行的源摘要、数据集与逐题 JSONL SHA-256 值, 并在论文写作前重新生成、与脚本输出逐字节比对。当前账本覆盖 MemoryAgentBench 各轨道 (两代引擎 $\times$ 三条答案路径、commit 455306d 处的官方评分器、一致的 entity2id 指纹)、LongMemEval 整批对话写入后的配对运行与 500 题运行、LoCoMo-1986/1540 及 K3 作答诊断、LoCoMo-Plus-401 (Li et al., 2026)、X7 通道诊断、源扩展诊断、修复后的预算前沿重放、MEME、BigCodeBench (Zhuo et al., 2025) 与 ALFWorld (Shridhar et al., 2021)。每次运行的清单记录数据集与提示词来源、模型标识符、工具观测、证据 ID、延迟、退出状态与代码/运行时哈希; 未通过完整性检查的结果与负面结果均予保留而非丢弃。账本生成与重算脚本随发布的补充材料一同提供, 因此该链条可端到端重建。

发布的补充材料包含重建每张表所需的机器可读清单、逐题分数、提示词与运行时哈希。论文在每个结果旁报告数据集、模型、评审、子集与完整性状态, 使比较保持可审计, 同时不暴露机器特定的存储位置。




图 5: 捆绑的 Base→Align+ 修订的配对构建诊断。(a) 入库调用与同名重复实体族在记录在案的 MAB 与 LongMemEval 交集上下降。(b) 配对的 MCC 与 FC-MH 切片各上升 3 个百分点; 区间保留, 因为这是捆绑比较而非组件消融。

属性	直接检索	工具辅助读取	原文读取
源访问	top- <i>k</i> 跨度	派生记录	逐字节文件
工具	无	记忆工具	读取、grep、脚本
答题模型	独立	独立	带验证的智能体
循环	无	多次只读调用	多次读取并核对
每题成本	27.5k tokens, 1.0 LLM calls	43.2k tokens, 6.5 LLM calls	328.6k tokens, 10.2 LLM calls

表 3: 三种读取方式的差异。三条路径共享冻结库、问题流、Kimi-K3 与官方评分器。

A.2 版本溯源与对齐 A/B 研究

随附的证据包补充了一项完整的三臂对齐研究 (LongMemEval-S) : 三个文档组 (42+49+46 份文档, 每臂 137 份文档)、先写入全部文档、同一 Kimi-K3 端点。臂 A 为不带批量候选检查的基线; B1 启用批量候选检查; B2 额外启用修订后的收敛实现 (并行对齐、推迟的非破坏性合并, 以及最后一致性检查)。保存的 B1 与 B2 服务配置逐字节相同; 二者的差异在运行时代码与 B2 开关上, 因此臂分配从清单与代码快照读出, 而不是从文件名推断。该研究的统计功效面向效率与整合而非质量: 每个文档组在每条评测轨道上只贡献一道题。

另一项 LME Base/Align+ 引擎差异 (初始/修订实现) 是从 commit 73d9c5e 到 8fa9651 的事后重建。后者还包含四项吞吐修复, 因此仅凭它无法确定 Align+ 运行中各时点哪些修复处于生效状态。我们以清单内嵌的流水线配置、运行时策略哈希与技能哈希为准; 重建的差异只是未提交代码的溯源材料, 并不是“每项后来的修复从首次修订运行起就已生效”的主张。

A.3 MEMORYAGENTBENCH 抽样框与污染说明

抽样子集按发布账本中记录的固定任务组清单抽取: 10 个任务组、59 份文档上的 767 题配对样本, 并在 Align+ 引擎上原地扩展四个任务组 (RULER-421K 多跳问答 100 题; 完整 Redial 推荐语料 200 题; 再加一个 DetectiveQA 任务组 6 题; 再加一个 ∞ Bench-Sum 任务组 1 题) 至 14 个任务组上的 1,074 题; 完整基准为 29 个任务、3,671 题。四种能力全部覆盖; 扩展后仍有 17 个任务未被抽样。配对样本及其 entity2id 指纹为全部六次运行 (三条路径 $\times$ 两代) 共享; 307 道扩展题仅存在于 Align+; 两个大型扩展文档组 (190 万与 570 万字符) 超出完整上下文参照 1,042,576 字符的严格预算, 因此参照覆盖为 1,074 题中的 614 题。参照使用中性提示词档案; 同一次运行的 normalized-v1 档案在其自身的 607 题覆盖上得 46.0 分——这是账本中保留的提示词敏感性痕迹, 不作为参照使用。文档组长度是异质的, 并在跨系统单元格领先的场合均予披露: 两个事实整合 (FactConsolidation) 文档组是 6K 变体 (各 26,157 字符); 32K/64K/262K 的 FC 变体 (13.6 万–110 万字符) 与其他未抽样文档组因预算被舍弃, 全部连同上下文大小列于发布账本的子集块中; EventQA 按 64K/128K/完整文档组抽样, 而非只取已发表的全本均值; LRU 域有 $n=7$ 道配对题与 14 道扩展题 (∞ Bench-Sum 先 1 后 2, DetectiveQA 先 6 后 12), 因此 LRU 单元格是方向性的。MAB 源语料是公开的; 答




图 6: 一条实测 LongMemEval 轨迹 (问题 2b8f3739): 概念追踪暴露出跨两份文档的四个会话片段指针, 另一次语义命中定位到第三条销售记录。七次成功调用耗时 13.96s; 第 8 步在一次格式错误的响应后达到上限, 随后一个独立的答题模型算出 $120 + 225 + (20 \times 7.5) = 495$ 。

RQ	记忆能力	基准与可观测预测
1	逐步读取原文	MemoryAgentBench 在相同的 767 题上比较直接检索、多次调用只读记忆工具与读取原文并核对引用。当智能体可以持续阅读时, 分数应当在事实整合与多次提及任务上拉开最大。
2	时序与多会话访问	LongMemEval 测试更新与跨会话链接。版本化观测应让较早与较晚的事实都仍然能被找到, 而偏好问题仍是潜在用户状态建模的边界。
3	关系整合	LoCoMo 区分单跳、多跳、时序与开放域问题。当答案需要连接多个会话片段或修订较早数值时, 概念族与关系路径应当最关键。
4	可修订构建	Base/Align+ 配对运行度量重复族、入库调用、token 与任务切片。渐进式对齐预测更低的构建成本与更好的整合, 但不要求分数全面上升。
5	删除与缺失边界	MEME 测试删除、级联与缺失。当前的只增存储应保留溯源, 但尚不能保证删除后的抑制。

表 4: 研究问题与测量方式。每一行检验检索——证据分离的一条不同预测; 已发表结果保留各自的测试条件, 便于检查分数差异。

题模型的预训练是否见过它们无法排除、也无法事后度量, 且每一行跨系统表格都声明自己的答题模型、评审与子集。

A.4 调整 OVERALL 的推导

配对样本漏掉了两个对所有人都得分很低的任务——AR 的 MH-QA 与 TTL 的推荐——早期草稿用插补处理: 代入已发表的全上下文参考值 (推荐 ≈ 13 、MH-QA ≈ 60) 后, 调整 Overall 为 ≈ 59.0 , 而配对样本口径的原始值为 65.1, 敏感性下的区间为 59–61。扩展取代了插补: 两个任务现在都在 Align+ 上直接测得 (读取原文 MH-QA 77.0、推荐 59.8; 表 1), 扩展 Overall 为 71.0, 两个任务都进入了聚合。扩展样本的构成仍与完整基准不同 (17 个任务未抽样), 因此我们继续只陈述原始值、绝不做跨样本口径的相减; 插补估计在此保留, 作为发布账本的溯源材料。

A.5 各路径提示词与配置

所有路径都用 Kimi-K3 作答, 提示词逐字存档于附录 A.1 所列的运行清单与代码快照中; 发布的补充材料完整重印它们。Base→Align+ 的引擎配置差异如下: 最大输出 token 16,384→32,768; 可用上下文窗口 32k→262,144; 重试 2→5; 超时 300s→1,200s;

臂	对齐修订	调用/文档	总 token/文档	实体重定向	重复组
A	基线	68.4	145,378	0	8
B1	批量候选检查	24.2	108,467	1	12
B2	批量检查 + 最后一致性检查	29.4	111,853	245	6

表 5: 每臂 137 份 LongMemEval-S 文档上的三臂对齐研究。B1 提供大幅效率下降; B2 在最后一致性检查上比 B1 多花约 3% 的 token, 是唯一具有实质非破坏性族重定向的臂, 降低了同名重复组。质量切片太小, 不足以做质量主张。B1 与 B2 使用同一份保存的服务配置; B2 的差别在运行时实现与对齐开关。




图 7: 冻结产物的运行点诊断 (Align+ 引擎; 面板 a 覆盖全部 1,074 题)。(a) 答案延迟的均值到 p95, 标注 token 数与调用数; (b) 配对的 Base→Align+ 入库成本; (c) 有效的固定排序检索预算前沿; (d) $k=10$ 处的仅源文档通道重放。

Align+ 启用绝对路径持久化。直接检索做一次融合检索调用与一次作答调用; 工具辅助读取会多次调用只读工具; 原文读取智能体物化一个文档组、读取并验证源文件, 且只提交通过引用检查的跨度。

A.6 附加定量诊断

账本还包含类型级更新分数、一次受控的源扩展重放, 以及 MEME 删除边界。图 8 报告这些量, 并让样本量与开发集限制保持可见。

A.7 载体参照 (BIGCODEBENCH (ZHUO ET AL., 2025)、ALFWORLD (SHRIDHAR ET AL., 2021))

BigCodeBench: 0.4859 完成率 / 0.2838 困难 pass@1 (校准切分)。ALFWORLD: 0.9786 同分布 / 0.9851 异分布成功率。两者都是对记忆不敏感的智能体载体回归测试: 它们锚定智能体载体能正确执行任务, 而不与记忆基准横向比较。

A.8 MAB 入库清单缺口

Base 与 Align+ 的 MAB 入库运行共享 45 份文档的配对交集。在某一代中缺失清单的文档被排除在每文档效率比之外, 因此效率比只在交集上计算 (每文档调用 609→329, -46%); token 比使用同一交集。题目级结果不受影响: 全部 767 道配对题在两代中都




图 8: 来自冻结账本的额外定量诊断。(a) 配对 Base/Align+ 轨道的 LongMemEval 类型分数; 这些方向性样本 $n=25/25/27$, 以粗略百分比显示。(b) 105 个历史错误案例上的源扩展召回对响应载荷; 这是开发诊断, 不是留出测试。(c) 带任务特定分母的 MEME 真实任务准确率, 暴露 0% 的删除边界。

表 6: X7 来源记录消融: 210 题检查集上的离线检索重放。臂 1-4 构成干净的通道消融: 只有 `enabled_channels` 不同, 因此任何召回差异都可归因于该通道集合。臂 5 (引用核对智能体, 开启检查) 与臂 6 (未被检索到的证据, 放宽检查) 复用臂 4 的五通道排序, 与臂 4 检索一致; 它们的区分列 (问答准确率、无支撑答案率、平均证据 token) 需要 LLM 智能体运行, 尚待完成。引用检查流程已离线验证: 开启检查时提交一个未浮现的对话轮会被拒绝; 放宽检查时同一提交被接受 (`plumbing_ok=true`)。在部署的 MAB 运行中, 检查按设计触发: 14/1074 questions in the deployed *v2* skill-agent run had an evidence submission rejected as unsurfaced (9/767 in *v1*); 11 of the 14 resubmitted tool-surfaced evidence inside the loop and the remaining 3 ended at the step cap and were answered from tool-surfaced context; zero rejections on the LME runs. Bootstrap 置信区间: 2,000 次重采样, 95%。

臂	通道 (累加)	Recall-any@10 [95% CI]	Recall-all@10 [95% CI]	平均字节 @10
1	raw-doc + episode-bm25	72.38 [66.67, 78.57]	51.43 [44.76, 58.10]	1833
2	+ semantic-provenance	72.38 [66.67, 78.57]	51.43 [44.76, 58.10]	1841
3	+ graph-neighbor	71.43 [65.70, 77.62]	50.95 [44.29, 57.62]	1845
4	+ relation-evidence (full 5)	72.38 [66.65, 78.57]	51.90 [45.24, 58.58]	1847

对着冻结库运行, 307 道扩展题只在 Align+ 引擎上运行, 因此入库成本比仍定义在配对交集上。

A.9 预算前沿

早期的一次 depth-10 对 depth-20 重放作为一项完整性发现被保留: 其前缀不变量在全部 210 题上失败 (`primary_result_invariant_violations=210`), 因此它不用于任何正面主张。修复后的设计对每个查询以最大深度只运行一次检索, 并把固定的排序切到 $k \in \{1, 3, 5, 10, 20\}$; 前缀单调性因此按构造成立 (零违例), 前沿从 $k=1$ 到 $k=20$ 单调上升, 每个 k 的百分位 bootstrap 置信区间从冻结的重放产物重新计算。

A.10 X7 通道消融细节

A.11 测试条件说明

原始 LoCoMo token-F1 轨道含 1,986 题与五个类别。Mem0 兼容轨道含 1,540 题与四个类别。LongMemEval-S 含 500 题; 整批写入后的配对运行使用节 4.1 所述的 $n=25/25/27$ 。MEME 的 100 个会话片段产生异质的任务数 (所引运行中 ER/Agg/Tr/Del/Cas/Abs 的事后检查数为 100/100/100/100/164/130)。raw 分数与 real 分数不可互换。

基准	协议	分数	答题 / 评审
LongMemEval-S (500)	抽样, $n=500$	84.60	Kimi-K3; Qwen3.7-plus 交叉评审
LongMemEval, 直接检索	配对, $n=25$	0.68 $\rightarrow$ 0.72	Kimi-K3 作答
LongMemEval, 工具辅助读取	配对, $n=25$	0.68 $\rightarrow$ 0.72	Kimi-K3 作答
LongMemEval, 原文读取	配对, $n=27$	0.889 $\rightarrow$ 0.926	Kimi-K3; 自评审
LoCoMo-1540	Mem0 J 评分	95.19	Kimi-K3; 作答 + 评审; $n=1$
LoCoMo-1540 (同一批答案)	交叉评审	94.22	Qwen3.7-plus; 一致率 98.51%

表 7: 其他基准在各自测试流程下的结果; 每行列出答题模型和评审模型。LoCoMo 运行与 Mem0 已发表的 J 有两处明示差异——单次运行对 10 次运行均值 $\pm$ 标准差, 以及作答/评审模型——并携带已披露的遗留指纹注意事项; 这些条件同时列出, 便于复核比较。LME 原文读取轨道多出的两题来自其会话证据规则; 比较只在同一测试轨道内进行。

A.12 保留的完整性失败

附录 A.9 的深度重放报告 `primary_result_invariant_violations=210` 且 `passed=false`。MEME 删除结果为 0% 的 real 准确率。X7 通道消融是零结果, 以等价界的形式报告而非丢弃。 ∞ Bench-Sum 的 $n=1$ 翻转直接使 Align+ Overall 损失 2.7 分 (Base $\rightarrow$ Align+ 净差距为 1.8 分), 并在每处比较中披露。LongMemEval 上直接检索与工具辅助读取打平的结果虽然对记忆工具路径不利, 仍予报告。这些记录保持可见, 因为一篇可审计的记忆论文应当同时暴露失败与零结果的机制, 而不只是成功的机制。

A.13 外部比较协议

Mem0 原论文报告 LoCoMo 类别级 F1、BLEU-1 与一个二值 J : GPT-4o-mini 评审把每个答案标为 CORRECT 或 WRONG, 得分即判定为 CORRECT 的百分比 (10 次独立运行的均值 $\pm$ 标准差)。Zep 原论文报告 DMR 与 LongMemEval, 答题模型为 GPT-4o 系列。我们不在自己的协议下重跑这些系统, 而是在下方逐字重印其已发表表格 (表 8-10) 作为不同测试流程下的参考结果。因篇幅从正文表格中省略的 Mem0 确定性 token 重叠指标重印于表 12。

K3 替换行。 放入 Mem0 J 列内的唯一一行 Deep-Dream J , 是用 Mem0 原样的二值评分方式、以 Kimi-K3 同时替换 GPT-4o-mini 的答题与评审角色得到的——唯一的改动就是模型。同模型 K3 评审下得 95.19% (S/M/O/T 为 97.38/93.62/80.21/95.33) ; 同一批 K3 答案经独立的 Qwen3.7-plus 交叉评审得 94.22% (96.91/92.91/77.08/93.46; 交叉评审一致率 98.51%)。相对 Mem0 已发表 J 的两处差异照例明示: 单次运行而非 10 次运行均值 $\pm$ 标准差; 模型为 Kimi-K3 而非 GPT-4o-mini。我们额外披露一条完整性注意事项: 该运行清单带有 `diagnostic_override={kind:legacy-missing-runtime-code-fingerprint, formal_claim_allowed:false}`, 因为 1,540 行答案中有 1,529 行来自早于运行时代码指纹机制的遗留源运行 (`legacy-source-run`)。答案本身未变 (`answer_rows_unchanged=true`, 答案 SHA-256 为 76af5772), 且逐题 JSONL 在全部 2,063 行上都带 `runtime_code_sha256` (3 个不同哈希: 2fa32774 覆盖 2,019 行、36b45933 覆盖 33 行、42afb1ac 覆盖 11 行), 数据集 SHA-256 (79fa87e9) 与库快照 (cf2e76b8) 与 Qwen 作答运行相同, Mem0 二值评审提示词也相同 (仓库 `mem0ai/memory-benchmarks`, commit 4b61c5d, 模式 `unified-no-evidence-exact-direct`)。因此我们把 95.19% 报告为诊断性交叉评审结果, 而不是指纹完备的正式条目。

更严格的受控比较——冻结相同的答题模型、评审模型、提示词、温度、证据预算、数据集修订版本与 Graphiti/Zep 实现 commit——仍是通向共享榜单的唯一途径; 但既然已发表数字被直接引用, 它不再是投稿的硬性门槛。

A.14 架构的信息论读法

本附录给论文的两条设计承诺一个形式化表述。每一条陈述要么是架构的结构性质（可对照 schema 与代码检查），要么是带显式假设的条件命题；没有一条提升节 4.2 and 4.8 的因果措辞纪律。

A.14.1 写入时：渐进式实体对齐

设不可变源流为 $S = D_1, \dots, D_T$ 。每条抽取出的提及产生一个特征向量 X_t ，包含名称与内容嵌入、属性以及关系端点共现。设 Z 为潜在实体指派， $M_t = (F_t, O_t, G_t)$ 为 t 条观测后的状态：概念族 F_t 、只增观测库 O_t 与关系图 G_t 。观测从不被摘要替换；它始终保持与其精确源跨度的链接。

$$\begin{aligned} O_{t+1} &= O_t \cup \{(X_{t+1}, \text{span}_{t+1})\}, \\ I(Z; O_{1:t+1}) &= I(Z; O_{1:t}) + I(Z; X_{t+1} \mid O_{1:t}) \geq I(Z; O_{1:t}). \end{aligned} \quad (4)$$

第二个恒等式是只增流的记账事实：新观测可以增加关于身份的信息，而已有证据不会被丢弃。它解释了系统为何不必在首次提及时就解出实体链接。低置信度合并成为一个额外的族（过切分）；之后的观测可以通过重定向指针族做合并，同时保留两边的观测集。过早的错误合并才是危险的错误，因为它把两个实体的证据污染进同一个检索位置。

命题 A.1 (可修订性). 在只增数据模型中，当前族划分的任何粗化都可以在之后由非破坏性合并实现，且不损失证据。若一个存储改为用滚动摘要 σ 覆写实体，则由数据处理不等式有 $I(Z; \sigma) \leq I(Z; O)$ ，且每当身份可判别的细节被丢弃时不等式严格。

命题 A.2 (汇聚证据下的收敛). 假设特征在给定实体身份时 *i.i.d.*，且两个不同实体 $e \neq e'$ 的输出分布 $P_e \neq P_{e'}$ 具有 Chernoff 信息 $C(P_e, P_{e'}) > 0$ 。对使用 k 条汇聚观测的同/异实体检验，似然比误差满足 $\Pr[\text{error}] \leq \exp[-kC(P_e, P_{e'})]$ (Chernoff, 1952)。因此，一个在弱证据下被初始拆分的真实合并未被察觉的概率，随佐证证据指数下降。

这些假设是理想化的：真实窗口相关、抽取噪声重尾、同名异实体对的 C 可能很小。因此该预测是定性的，而不是一个实测收敛速率。它与实现的批量处理和末尾复查一致——后者用更多汇聚上下文重测候选族。在配对引擎运行中，同名重复组从 340→124 (MAB)、482→99 (LME)，每文档入库调用下降 46–65%；这些是实测参考值，不是对 C 的估计。关系边承担两个角色：端点共现在写入时帮助区分假设，所得的图在读取时提供额外路径。

A.14.2 读取时：层级检索位置与渐进披露

派生层是一个检索索引，而不是答案重构。设 $A_t(q)$ 把问题映射到概念族与关系邻域， ρ 为选择打开哪些候选的智能体策略。所得的源上下文构成一条自适应链

$$C_0(q) \subseteq C_1(q) \subseteq \dots \subseteq S, \quad a_{k+1} = \rho(q, M_t, C_{\leq k}, u_k), \quad (5)$$

其中 u_k 是智能体的当前不确定性。概念搜索给出快速的宏观检索线索；族观测与关系边对其精化；最终读取返回确切的会话片段与跨度。这正是同一表示既支持自主探索、又支持读取原文答案的原因。

把重构失真定义为被引用文本与其声称代表的源文本之间的差异，把寻址损失定义为未能把相关源跨度放入 C_k 。由于每条路径都把候选解析到逐字源跨度、且引用检查只接受当前回合浮现的跨度，重构失真按构造为零；全部残余损失都是寻址损失。摘要式记忆在写入时固定一个率-失真点，而 ρ 逐查询选择阅读预算 (Shannon, 1959)。智能体可以在一次紧凑的概念查询后停止，也可以在不确定性仍高时披露更多邻域与源文件，而不改变证据的权威性。

表 8: LoCoMo 分类别 J (二值 CORRECT/WRONG 准确率, LLM 评审)。已发表行逐字复现自 Chhikara et al. (2025) (arXiv:2504.19413, 表 1): Mem0 报告 10 次运行的均值 $\pm$ 标准差, 答题与评审均为 GPT-4o-mini (标准差省略, 全部 ≤ 0.75)。Deep-Dream 应用固定在仓库提交 4b61c5d 的二值 J 评分规则——该 2026 修订版评审提示的容差规则异于 2025 年论文的附录 A——以 Kimi-K3 同时作答与评审 (单次运行); $\dagger$ 行用独立的 Qwen3.7-plus 交叉评审评判同一批 K3 答案 (交叉评审一致率 98.51%)。相同的 841/282/96/321 题目群体 (共 1,540 题, Mem0 兼容子集)。注意事项: K3 作答运行被标记 `formal_claim_allowed=false`——1,529 条历史答案行早于运行时代码指纹 (答案未变, sha 76af5772; 逐条 JSONL 携带 `runtime_code_sha256`)。作为诊断性交叉评审结果报告, 而非指纹完备的正式结果。确定性的 F1/BLEU-1 因篇幅省略 (表 12)。加权 J (由已发表分类均值按 841/282/96/321 题量重加权): Mem0 ≈ 62.14 , Mem0^g ≈ 61.36 ; 其论文表 2 另报 Overall $J = 66.88$ (Mem0) 与 68.44 (Mem0^g)。Deep-Dream 聚合 J : 95.19% / 94.22% ($\dagger$)。表体为已发表数据的逐字复现, 保留英文。

Method	J (S/M/O/T)			
LoCoMo	—	/	—	/
ReadAgent	—	/	—	/
MemoryBank	—	/	—	/
MemGPT	—	/	—	/
A-Mem	—	/	—	/
A-Mem*	39.79	/	18.85	/
LangMem	62.23	/	47.92	/
Zep	61.70	/	41.35	/
OpenAI	63.79	/	42.92	/
Mem0	67.13	/	51.15	/
Mem0 ^g	65.71	/	47.19	/
Deep-Dream	97.38	/	93.62	/
Deep-Dream [†]	96.91	/	92.91	/

A.14.3 双速率分解与答案风险

设 $A(q)$ 为派生派生图输出检索位置, E_C 为候选集 C 选出的精确源跨度。对答案相关变量 Y , 链式法则给出

$$I(Y; A, E_C | Q = q) = I(Y; A | Q = q) + I(Y; E_C | A, Q = q). \quad (6)$$

第一项是紧凑概念/关系检索位置提供的信息; 第二项是打开源文本才获得的信息。纯摘要记忆把 S 替换为信道输出 $\tilde{S} = f(S)$, 无法使 $I(Y; \tilde{S} | Q)$ 超过 $I(Y; S | Q)$; Deep-Dream 则在寻址之后仍保持源信道可用。这是一种信息瓶颈解释, 而不是“实现解决了该瓶颈变分问题”的主张 (Tishby et al., 2000)。

为完整起见, 设 R_q 为相关源跨度被寻址这一事件, V_q 为验证者在读取后正确作答这一事件。则

$$\Pr[\hat{Y} = Y | q] \geq \Pr[R_q | q] \Pr[V_q | R_q, q]. \quad (7)$$

派生图主要影响检索位置召回, 逐步读取原文影响条件验证。引用检查在其显式可达性契约下把引用来源错误的概率设为零; 语义不相关仍在保证之外。该分解解释了为什么改进应当在需要多次提及、时序更新或事实整合的问题上最大, 以及为什么仅图的离线召回变化不必预测完整的在线增益。

扩展样本上 Align+ 的实测运行点为 (27.5k token, 0.333)、(43.2k, 0.400) 与 (328.6k, 0.710) 的 Overall; 冻结在配对样本上的 Base 代复现了该次序 (0.3025/0.3759/0.6695)。FC-MH 分数 (2–4 对 67–70) 显示了自适应源阅读在何处最重要。X7 在开发切片上把派生通道的离线检索贡献界定在 ± 2.4 分以内; 派生图层的在线价值是文档组选择与链接扩展, 由原文读取智能体行使, 而不会被该消融移除。

命题 A.3 (单侧寻址错误). 对任何派生图状态, A_t 中的错误可以改变哪些跨度进入 C_k , 但不能改变被引用检查接纳的跨度的文本或溯源。因此派生图错误造成的是覆盖缺失, 而不是捏造的引用内容; 该保证是被引用原文是否被打开, 不是语义蕴含。

这套表述增加了数学结构, 但没有提升阶梯的因果措辞: 指数陈述是有条件的, 重名计数是代理量, 实测的阶梯仍是一个系统比较。

表 9: 已发表的深度记忆检索 (DMR) 基线, 逐字复现自 Rasmussen et al. (2025) (arXiv:2501.13956)。DMR 包含 500 段多会话对话 (5 个会话、每会话 ≤ 12 条消息), 每段对话一道单跳事实检索题。Deep-Dream 目前未运行 DMR, 因此本表仅作上下文参照。表体保留英文原文。

Method	Answerer	Accuracy
Recursive Summarization	GPT-4-turbo	35.3%
Conversation Summaries	GPT-4-turbo	78.6%
MemGPT	GPT-4-turbo	93.4%
Full-conversation	GPT-4-turbo	94.4%
Zep	GPT-4-turbo	94.8%
Conversation Summaries	GPT-4o-mini	88.0%
Full-conversation	GPT-4o-mini	98.0%
Zep	GPT-4o-mini	98.2%

表 10: LongMemEval 主要结果。已发表行 (GPT-4o-mini / GPT-4o, 全上下文对 Zep) 逐字复现自 Rasmussen et al. (2025) (arXiv:2501.13956)。**Deep-Dream** 行使用 Qwen3.7-plus 同时作答与交叉评审——这是一个不同的协议; 其准确率 (84.6%) 被放在已发表数字旁边, 而非共享榜单。Deep-Dream 的延迟/平均上下文未在已发表协议下测量 (—)。六类别分解见表 11。表体保留英文原文。

Answerer	System	Accuracy	Latency (s)	Avg. context
GPT-4o-mini	Full-context	55.4%	31.30	115k
GPT-4o-mini	Zep	63.8%	3.20	1.6k
GPT-4o	Full-context	60.2%	28.90	115k
GPT-4o	Zep	71.2%	2.58	1.6k
Qwen3.7-plus	Deep-Dream	84.6%	—	—

表 11: LongMemEval 六类别分解 (二值准确率, %)。已发表的全上下文与 Zep 数值逐字复现自 Rasmussen et al. (2025) (arXiv:2501.13956); **Deep-Dream (Q.)** 行是 Qwen3.7-plus 作答 + 交叉评审在相同六个类别上的结果。答题/评审不同, 因此这是粒度匹配的上下文参照, 不是共享榜单。会话偏好 (Sess. pref.) 是所有系统最难的类别。表体保留英文原文。

System	Sess. pref.	Sess. asst.	Temporal	Multi-sess.	Knowledge upd.	Sess. user
Full-ctx (4o-mini)	30.0	81.8	36.5	40.6	76.9	81.4
Zep (4o-mini)	53.3	75.0	54.1	47.4	74.4	92.9
Full-ctx (4o)	20.0	94.6	45.1	44.3	78.2	81.4
Zep (4o)	56.7	80.4	62.4	57.9	83.3	92.9
Deep-Dream (Q.)	53.3	100.0	84.2	74.4	91.0	98.6

表 12: Mem0 LoCoMo 确定性指标, 逐字复现自 Chhikara et al. (2025) (表 1)。四个类别 (单跳/多跳/开放域/时序) 上的 F1 / BLEU-1。Deep-Dream 不计算 token 重叠指标 (其指标为二值 LLM 评审准确率, 表 8), 因此这里没有 Deep-Dream 列; 本表仅为完整性而收录已发表的复现。表体保留英文原文。

Method	F1 (S/M/O/T)	BLEU-1 (S/M/O/T)
LoCoMo	25.02 / 12.04 / 40.36 / 18.41	19.75 / 11.16 / 29.05 / 14.77
ReadAgent	9.15 / 5.31 / 9.67 / 12.60	6.48 / 5.12 / 7.66 / 8.87
MemoryBank	5.00 / 5.56 / 6.61 / 9.68	4.77 / 5.94 / 5.16 / 6.99
MemGPT	26.65 / 9.15 / 41.04 / 25.52	17.72 / 7.44 / 34.34 / 19.44
A-Mem	27.02 / 12.14 / 44.65 / 45.85	20.09 / 12.00 / 37.06 / 36.67
A-Mem*	20.76 / 9.22 / 33.34 / 35.40	14.90 / 8.81 / 27.58 / 31.08
LangMem	35.51 / 26.04 / 40.91 / 30.75	26.86 / 22.32 / 33.63 / 25.84
Zep	35.74 / 19.37 / 49.56 / 42.00	23.30 / 14.82 / 38.92 / 34.53
OpenAI	34.30 / 20.09 / 39.31 / 14.04	23.72 / 15.42 / 31.16 / 11.25
Mem0	38.72 / 28.64 / 47.65 / 48.93	27.13 / 21.58 / 38.72 / 40.51
Mem0 ^g	38.09 / 24.32 / 49.27 / 51.55	26.03 / 18.82 / 40.30 / 40.28